


Uma Abordagem Baseada em *Parallel Tempering* para o Problema de Minimização de Pilhas Abertas

Mauro Lúcio A. P. Santos Filho Marco Antonio M. Carvalho


Programa de Pós-Graduação em Ciência da Computação
Universidade Federal de Ouro Preto



- 1 O problema
- 2 Literatura
- 3 *Parallel Tempering*
- 4 PT-MOSP
- 5 Experimentos e resultados
- 6 Conclusão


Corte de estoque

- ▶ Vidro, metalurgia, têxtil, mobiliário.
- ▶ **Padrão de corte:** forma de cortar uma placa em peças de um ou mais tipos de item.
- ▶ Cada tipo de item ocupa uma pilha no estoque intermediário.
- ▶ Espaço restrito. Pilhas não devem ser movimentadas.



Corte de estoque


- ▶ Vidro, metalurgia, têxtil, mobiliário.
- ▶ **Padrão de corte:** forma de cortar uma placa em peças de um ou mais tipos de item.
- ▶ Cada tipo de item ocupa uma pilha no estoque intermediário.
- ▶ Espaço restrito. Pilhas não devem ser movimentadas.




MOSP

Ordenar os padrões de corte minimizando o **número máximo de pilhas abertas simultaneamente**.

Padrões de corte




Padrões de corte



Regra das pilhas

- ▶ **Abre** no primeiro padrão que produz o item.
- ▶ **Fecha** no último padrão que ainda produz o item.


Padrões de corte




Regra das pilhas

- ▶ **Abre** no primeiro padrão que produz o item.
- ▶ **Fecha** no último padrão que ainda produz o item.
- ▶ Entre abrir e fechar, a pilha continua aberta mesmo nos padrões que não produzem o item (pilha **ociosa**).

Dinâmica das pilhas




Dinâmica das pilhas



$$\pi = [j_3, j_6, j_2, j_5, j_4, j_1]$$

► No máximo 3 pilhas abertas.


Dinâmica das pilhas




$$\pi = [j_3, j_6, j_2, j_5, j_4, j_1]$$

- ▶ No máximo 3 pilhas abertas.
- ▶ Pequenas trocas na ordem mudam muito esse valor.

Dinâmica das pilhas: trocando dois padrões




Dinâmica das pilhas: trocando dois padrões



$$\pi' = [j_3, j_1, j_2, j_5, j_4, j_6]$$

- Só j_6 e j_1 trocaram de lugar. O máximo sobe de 3 para 6: todas as pilhas abertas.

Dinâmica das pilhas: trocando dois padrões



$$\pi' = [j_3, j_1, j_2, j_5, j_4, j_6]$$

- ▶ Só j_6 e j_1 trocaram de lugar. O máximo sobe de 3 para 6: todas as pilhas abertas.
- ▶ A ordem anterior é ótima. Uma única troca dobra o valor.

Definição

Entrada

Um conjunto de padrões e os tipos de item que cada padrão produz.

Definição

Entrada

Um conjunto de padrões e os tipos de item que cada padrão produz.

Solução

Uma ordem de processamento dos padrões.

Definição

Entrada

Um conjunto de padrões e os tipos de item que cada padrão produz.

Solução

Uma ordem de processamento dos padrões.

Objetivo

Minimizar o número máximo de pilhas abertas simultaneamente.

Definição

Entrada

Um conjunto de padrões e os tipos de item que cada padrão produz.

Solução

Uma ordem de processamento dos padrões.

Objetivo

Minimizar o número máximo de pilhas abertas simultaneamente.

NP-difícil [Yanasse, 1997]

Não se conhece algoritmo determinístico de tempo polinomial. Em instâncias grandes, métodos exatos ficam caros, o que motiva heurísticas e meta-heurísticas.

20 trabalhos (1979–2023)

- ▶ 9 exatos ou teóricos.
- ▶ 7 heurísticas.
- ▶ 4 meta-heurísticas.

20 trabalhos (1979–2023)

- ▶ 9 exatos ou teóricos.
- ▶ 7 heurísticas.
- ▶ 4 meta-heurísticas.

Métodos de referência para comparação

- ▶ Heurística: *PieceRank* [Frinhani et al., 2018].
- ▶ Meta-heurísticas: BRKGA [2016] e VND [2017].

20 trabalhos (1979–2023)

- ▶ 9 exatos ou teóricos.
- ▶ 7 heurísticas.
- ▶ 4 meta-heurísticas.

Métodos de referência para comparação

- ▶ Heurística: *PieceRank* [Frinhani et al., 2018].
- ▶ Meta-heurísticas: BRKGA [2016] e VND [2017].

Benchmark fragmentado

- ▶ 6 conjuntos de instâncias, cada um de um grupo diferente.
- ▶ Dimensões de 10×10 a 1000×1000 .
- ▶ Clássicos: maioria dos ótimos já obtida por Chu e Stuckey [2009].

Ideia

- ▶ Várias buscas ao mesmo tempo: L réplicas.
- ▶ Cada réplica é uma **cadeia de Markov** com temperatura fixa, $T_1 < \dots < T_L$.

Ideia

- ▶ Várias buscas ao mesmo tempo: L réplicas.
- ▶ Cada réplica é uma **cadeia de Markov** com temperatura fixa, $T_1 < \dots < T_L$.

Aceitação na cadeia: critério de Metropolis

$$P(s \rightarrow s', T) = \begin{cases} 1, & f(s') \leq f(s), \\ \exp\left(-\frac{f(s') - f(s)}{T}\right), & \text{caso contrário.} \end{cases}$$

Parallel Tempering

Ideia

- ▶ Várias buscas ao mesmo tempo: L réplicas.
- ▶ Cada réplica é uma **cadeia de Markov** com temperatura fixa, $T_1 < \dots < T_L$.

Aceitação na cadeia: critério de Metropolis


$$P(s \rightarrow s', T) = \begin{cases} 1, & f(s') \leq f(s), \\ \exp\left(-\frac{f(s') - f(s)}{T}\right), & \text{caso contrário.} \end{cases}$$

- ▶ T alta: aceita pioras com facilidade. **Diversifica**.
- ▶ T baixa: quase só aceita melhoras. **Intensifica**.

Trocas entre temperaturas

Probabilidade de troca

$$P(r_i \leftrightarrow r_j) = \min \left\{ 1, e^{\left(\frac{1}{T_j} - \frac{1}{T_i} \right) (f(r_j) - f(r_i))} \right\}$$




Trocas entre temperaturas

Probabilidade de troca

$$P(r_i \leftrightarrow r_j) = \min \left\{ 1, e^{\left(\frac{1}{T_j} - \frac{1}{T_i} \right) (f(r_j) - f(r_i))} \right\}$$

- Boas soluções descem para T **baixa**: refinamento.




Trocas entre temperaturas

Probabilidade de troca

$$P(r_i \leftrightarrow r_j) = \min \left\{ 1, e^{\left(\frac{1}{T_j} - \frac{1}{T_i} \right) (f(r_j) - f(r_i))} \right\}$$

- ▶ Boas soluções descem para T **baixa**: refinamento.
- ▶ Soluções estagnadas sobem para T **alta**: fuga de ótimos locais.




Trocas entre temperaturas

Probabilidade de troca

$$P(r_i \leftrightarrow r_j) = \min \left\{ 1, e^{\left(\frac{1}{T_j} - \frac{1}{T_i} \right) (f(r_j) - f(r_i))} \right\}$$

- ▶ Boas soluções descem para T **baixa**: refinamento.
- ▶ Soluções estagnadas sobem para T **alta**: fuga de ótimos locais.



Intrinsecamente paralelo

Entre as trocas, as réplicas são independentes. Uma por *thread*.

PT-MOSP: adaptações ao problema

Representação

Permutação de padrões ou de tipos de item.

Vizinhança

Swap, *2-opt* ou inserção aleatória.

PT-MOSP: adaptações ao problema

Representação

Permutação de padrões ou de tipos de item.

Vizinhança

Swap, *2-opt* ou inserção aleatória.

Solução inicial

Aleatória ou construída pela MCNh [Becceneri et al., 2004].

Parada

Número fixo de propostas de troca entre réplicas.

PT-MOSP: adaptações ao problema

Representação

Permutação de padrões ou de tipos de item.

Solução inicial

Aleatória ou construída pela MCNh [Becceneri et al., 2004].

Avaliação

Número máximo de pilhas abertas.

Vizinhança

Swap, *2-opt* ou inserção aleatória.

Parada

Número fixo de propostas de troca entre réplicas.

Implementação

C++ sobre a API de Almeida et al. [2025].
Uma réplica por *thread*.

Conjunto	Referência	Qtd.	Dimensões
SCOOP	Santos e de Carvalho [2018]	24	até 49×134
Faggioli e Bentivoglio	Faggioli e Bentivoglio [1998]	300	até 40×50
First Constraint	Smith e Gent [2005]	46	até 100×100
<i>Large Artificial</i>	Chu e Stuckey [2009]	200	até 125×125
<i>Larger and Harder</i>	Carvalho e Soma [2015]	150	até 200×200
Grandes dimensões	Frinhani et al. [2018]	610	400×400 a 1000×1000

Conjunto	Referência	Qtd.	Dimensões
SCOOP	Santos e de Carvalho [2018]	24	até 49×134
Faggioli e Bentivoglio	Faggioli e Bentivoglio [1998]	300	até 40×50
First Constraint	Smith e Gent [2005]	46	até 100×100
<i>Large Artificial</i>	Chu e Stuckey [2009]	200	até 125×125
<i>Larger and Harder</i>	Carvalho e Soma [2015]	150	até 200×200
Grandes dimensões	Frinhani et al. [2018]	610	400×400 a 1000×1000

Papel de cada conjunto

- ▶ 720 clássicas: teste de consistência.

Conjunto	Referência	Qtd.	Dimensões
SCOOP	Santos e de Carvalho [2018]	24	até 49×134
Faggioli e Bentivoglio	Faggioli e Bentivoglio [1998]	300	até 40×50
First Constraint	Smith e Gent [2005]	46	até 100×100
<i>Large Artificial</i>	Chu e Stuckey [2009]	200	até 125×125
<i>Larger and Harder</i>	Carvalho e Soma [2015]	150	até 200×200
Grandes dimensões	Frinhani et al. [2018]	610	400×400 a 1000×1000

Papel de cada conjunto

- ▶ 720 clássicas: teste de consistência.
- ▶ 610 grandes: núcleo da avaliação, com densidades variadas.

Componente	Opções (selecionada)
Codificação	padrões; tipos de item
Solução inicial	aleatória; MCNh
Vizinhança	<i>swap</i> ; <i>2-opt</i> ; inserção aleatória
T_1	0,01 ; 0,1; 1
T_L	3; 5; 10
Cadeia de Markov	300; 400; 500; 600 ; 700
Distribuição	linear; inverso linear ; exponencial; geométrica

Componente	Opções (selecionada)
Codificação	padrões; tipos de item
Solução inicial	aleatória; MCNh
Vizinhança	<i>swap</i> ; <i>2-opt</i> ; inserção aleatória
T_1	0,01 ; 0,1; 1
T_L	3; 5; 10
Cadeia de Markov	300; 400; 500; 600 ; 700
Distribuição	linear; inverso linear ; exponencial; geométrica

Parâmetros fixos

11 réplicas e 2000 propostas de troca entre réplicas.

Métodos comparados

- ▶ *PieceRank* [Frinhani et al., 2018]: heurística de passada única. Tempo não comparado.

Métodos comparados

- ▶ *PieceRank* [Frinhani et al., 2018]: heurística de passada única. Tempo não comparado.
- ▶ BRKGA [Gonçalves et al., 2016] e VND [Lima e Carvalho, 2017]: limite de 18 min por instância, com margem sobre o maior tempo do PT-MOSP.

Métodos comparados

- ▶ *PieceRank* [Frinhani et al., 2018]: heurística de passada única. Tempo não comparado.
- ▶ BRKGA [Gonçalves et al., 2016] e VND [Lima e Carvalho, 2017]: limite de 18 min por instância, com margem sobre o maior tempo do PT-MOSP.

Execução

- ▶ Dez execuções por instância.
- ▶ Intel Core i7-10700, 16 GB, 11 *threads*.
- ▶ g++ 11.4.0 -03.

Benchmark clássico: consistência

Conjunto

- ▶ 720 instâncias de cinco famílias.
- ▶ Ótimos conhecidos, exceto em 59 instâncias do conjunto *Larger and Harder*.

Benchmark clássico: consistência

Conjunto

- ▶ 720 instâncias de cinco famílias.
- ▶ Ótimos conhecidos, exceto em 59 instâncias do conjunto *Larger and Harder*.

Resultados

- ▶ Empate com a melhor solução conhecida em 640 de 720 instâncias (88,9%).

Benchmark clássico: consistência

Conjunto

- ▶ 720 instâncias de cinco famílias.
- ▶ Ótimos conhecidos, exceto em 59 instâncias do conjunto *Larger and Harder*.

Resultados

- ▶ Empate com a melhor solução conhecida em 640 de 720 instâncias (88,9%).
- ▶ Superou a melhor solução conhecida em 1 instância e não a alcançou em 79.

Benchmark clássico: consistência

Conjunto

- ▶ 720 instâncias de cinco famílias.
- ▶ Ótimos conhecidos, exceto em 59 instâncias do conjunto *Larger and Harder*.

Resultados

- ▶ Empate com a melhor solução conhecida em 640 de 720 instâncias (88,9%).
- ▶ Superou a melhor solução conhecida em 1 instância e não a alcançou em 79.
- ▶ Em média, cerca de 6% melhor que o *PieceRank*.

Benchmark clássico: consistência

Conjunto

- ▶ 720 instâncias de cinco famílias.
- ▶ Ótimos conhecidos, exceto em 59 instâncias do conjunto *Larger and Harder*.

Resultados

- ▶ Empate com a melhor solução conhecida em 640 de 720 instâncias (88,9%).
- ▶ Superou a melhor solução conhecida em 1 instância e não a alcançou em 79.
- ▶ Em média, cerca de 6% melhor que o *PieceRank*.

Leitura

Conjunto maduro, com pouca margem para diferenciar métodos bem ajustados.

Grandes dimensões

Dimensão	PT-MOSP	<i>PieceRank</i>	BRKGA	VND
400 × 400	312,79	319,11	345,46	333,43
600 × 600	485,64	493,76	531,97	521,20
800 × 800	672,49	680,99	723,74	723,69
1000 × 1000	849,34	858,31	911,14	925,41

Dimensão	PT-MOSP	<i>PieceRank</i>	BRKGA	VND
400 × 400	312,79	319,11	345,46	333,43
600 × 600	485,64	493,76	531,97	521,20
800 × 800	672,49	680,99	723,74	723,69
1000 × 1000	849,34	858,31	911,14	925,41

Destaques

- ▶ Melhor média nas quatro dimensões.

Dimensão	PT-MOSP	<i>PieceRank</i>	BRKGA	VND
400 × 400	312,79	319,11	345,46	333,43
600 × 600	485,64	493,76	531,97	521,20
800 × 800	672,49	680,99	723,74	723,69
1000 × 1000	849,34	858,31	911,14	925,41

Destaques

- ▶ Melhor média nas quatro dimensões.
- ▶ Melhor que BRKGA e VND em **610** das **610** instâncias.

Dimensão	PT-MOSP	<i>PieceRank</i>	BRKGA	VND
400 × 400	312,79	319,11	345,46	333,43
600 × 600	485,64	493,76	531,97	521,20
800 × 800	672,49	680,99	723,74	723,69
1000 × 1000	849,34	858,31	911,14	925,41

Destaques

- ▶ Melhor média nas quatro dimensões.
- ▶ Melhor que BRKGA e VND em **610** das **610** instâncias.
- ▶ PT-MOSP: 2,7 a 10,1 min. BRKGA e VND no teto de 18 min.

Distância média

- ▶ *PieceRank*: 1,50%.
- ▶ VND: 7,08%.
- ▶ BRKGA: 8,01%.

Distância média

- ▶ *PieceRank*: 1,50%.
- ▶ VND: 7,08%.
- ▶ BRKGA: 8,01%.

Wilcoxon

Superior aos três métodos em todas as dimensões, $p \leq 1,8 \times 10^{-3}$.

Distância média

- ▶ *PieceRank*: 1,50%.
- ▶ VND: 7,08%.
- ▶ BRKGA: 8,01%.

Wilcoxon

Superior aos três métodos em todas as dimensões, $p \leq 1,8 \times 10^{-3}$.

Densidade: redução média de pilhas do PT-MOSP

Instâncias	vs <i>PieceRank</i>	vs VND	vs BRKGA
Esparsas	6,9%	18,4%	24,3%
Média densidade	0,6%	2,1%	3,8%
Densas	0,1%	0,5%	0,8%

Nas densas, os ótimos se concentram e as diferenças encolhem.

Contribuições

- ▶ PT adaptado ao MOSP com componentes calibrados.

Contribuições

- ▶ PT adaptado ao MOSP com componentes calibrados.
- ▶ Consistente no *benchmark* clássico.

Contribuições

- ▶ PT adaptado ao MOSP com componentes calibrados.
- ▶ Consistente no *benchmark* clássico.
- ▶ Superior a *PieceRank*, BRKGA e VND em grande escala.

Contribuições

- ▶ PT adaptado ao MOSP com componentes calibrados.
- ▶ Consistente no *benchmark* clássico.
- ▶ Superior a *PieceRank*, BRKGA e VND em grande escala.
- ▶ Mais processamento compensa em instâncias grandes e heterogêneas.

Contribuições

- ▶ PT adaptado ao MOSP com componentes calibrados.
- ▶ Consistente no *benchmark* clássico.
- ▶ Superior a *PieceRank*, BRKGA e VND em grande escala.
- ▶ Mais processamento compensa em instâncias grandes e heterogêneas.

Limitações

- ▶ Ganhos pequenos em instâncias densas.
- ▶ Mais lento que o *PieceRank*, que responde em segundos.

Conclusão

Contribuições

- ▶ PT adaptado ao MOSP com componentes calibrados.
- ▶ Consistente no *benchmark* clássico.
- ▶ Superior a *PieceRank*, BRKGA e VND em grande escala.
- ▶ Mais processamento compensa em instâncias grandes e heterogêneas.

Limitações

- ▶ Ganhos pequenos em instâncias densas.
- ▶ Mais lento que o *PieceRank*, que responde em segundos.

Trabalhos futuros

- ▶ Seleção adaptativa de vizinhança.
- ▶ Outras políticas de orçamento computacional.
- ▶ Triagem de métodos exatos em grande escala (em andamento).

Uma Abordagem Baseada em *Parallel Tempering* para o Problema de Minimização de Pilhas Abertas

Mauro Lúcio A. P. Santos Filho Marco Antonio M. Carvalho


Programa de Pós-Graduação em Ciência da Computação
Universidade Federal de Ouro Preto

Obrigado!

mauro.paulino@aluno.ufop.edu.br



PT-MOSP



API de *Parallel Tempering*