

UNIVERSIDADE FEDERAL DE OURO PRETO
INSTITUTO DE CIÊNCIAS EXATAS E BIOLÓGICAS
DEPARTAMENTO DE COMPUTAÇÃO

HEBERT LUIZ MADEIRA PASCOAL
Orientador: Marco Antonio Moreira de Carvalho

**APLICANDO O REVENIMENTO PARALELO NA MINIMIZAÇÃO DO
MAKESPAN EM MÁQUINAS PARALELAS NÃO RELACIONADAS
COM TEMPOS DE PREPARO, DISPONIBILIDADE DAS TAREFAS E
RESTRIÇÃO DE CONSUMO DE RECURSOS**

Ouro Preto, MG
2026

UNIVERSIDADE FEDERAL DE OURO PRETO
INSTITUTO DE CIÊNCIAS EXATAS E BIOLÓGICAS
DEPARTAMENTO DE COMPUTAÇÃO

HEBERT LUIZ MADEIRA PASCOAL

**APLICANDO O REVENIMENTO PARALELO NA MINIMIZAÇÃO DO MAKESPAN
EM MÁQUINAS PARALELAS NÃO RELACIONADAS COM TEMPOS DE PREPARO,
DISPONIBILIDADE DAS TAREFAS E RESTRIÇÃO DE CONSUMO DE RECURSOS**

Monografia apresentada ao Curso de Ciência da Computação da Universidade Federal de Ouro Preto como parte dos requisitos necessários para a obtenção do grau de Bacharel em Ciência da Computação.

Orientador: Marco Antonio Moreira de Carvalho

Ouro Preto, MG
2026

DECLARAÇÃO DE USO DE INTELIGÊNCIA ARTIFICIAL GENERATIVA

Durante a preparação deste documento, eu, Hebert Luiz Madeira Pascoal, estudante de graduação em Ciência da Computação na Universidade Federal de Ouro Preto, declaro o uso da Inteligência Artificial Generativa ChatGPT, modelo GPT-4o mini, como apoio à revisão textual, à geração de trechos de código em L^AT_EX e à organização preliminar da revisão bibliográfica.

Após o uso desta ferramenta/modelo/serviço, a pessoa autora revisou e editou o conteúdo em conformidade com os princípios éticos para uso de IAGen (Resolução CONPEP nº 144) e com os acordos estabelecidos com a pessoa orientadora da pesquisa. Dessa forma, assumo total responsabilidade pelo conteúdo da publicação.

Resumo

O problema de minimização do *makespan* em máquinas paralelas não relacionadas, com tempos de preparo dependentes da sequência, datas de disponibilidade e restrição de consumo de recursos, modela cenários operacionais realistas. Entretanto, sua complexidade computacional o caracteriza como NP-difícil, inviabilizando a resolução do problema para instâncias modestamente grandes na prática. Não obstante, na literatura, há uma quantidade limitada de trabalhos que se propõem a estudar essa classe de problemas de escalonamento. O revenimento paralelo foi revitalizado recentemente no contexto da otimização combinatória, apresentando grande potencial em problemas de escalonamento. Esta monografia se insere nesse panorama ao propor avaliar o revenimento paralelo aplicado a esse problema específico. Nesta primeira parte da monografia, o problema é formalizado, a teoria que fundamenta o método é apresentada e a literatura é revisitada quanto à classe de problemas abordada. Esses elementos estabelecem a base para o desenvolvimento e a conclusão do trabalho posteriormente.

Abstract

The problem of minimizing the maximum completion time of tasks, or *makespan*, on unrelated parallel machines with sequence-dependent setup times, release dates, and resource consumption constraints models realistic operational scenarios. However, its computational complexity characterizes it as NP-hard, making the resolution of the problem infeasible for moderately large instances in practice. Nevertheless, the literature contains a limited number of works that investigate this class of scheduling problems. Parallel tempering has recently been revitalized in the context of combinatorial optimization, showing great potential for scheduling problems. This monograph fits within this context by proposing an evaluation of parallel tempering applied to this specific problem. In this first part of the monograph, the problem is formalized, the theory underlying the method is presented, and the literature regarding the addressed problem class is reviewed. These elements establish the foundation for the subsequent development and conclusion of the work.

Lista de Ilustrações

Figura 2.1 – Gráfico de Gantt para uma solução da instância de exemplo.	8
Figura 2.2 – Gráfico de Gantt para uma melhor solução da instância de exemplo.	9
Figura 2.3 – Ilustração conceitual de um mínimo local separado do mínimo global por uma barreira energética. O eixo das abscissas corresponde ao estado x , ao passo que o eixo das ordenadas corresponde à energia desses estados. . . .	13
Figura 2.4 – Exemplo de funcionamento do intercâmbio de temperaturas no PT. Aqui, $\nu = 6$ e $Q = 12$. As temperaturas estão arranjadas verticalmente. Cada linha colorida representa uma réplica diferente, e temperaturas adjacentes ocasionalmente trocam de réplicas à medida em que se avança na iteração de t , representada na horizontal. As trocas são enumeradas, de 1 a 10, de acordo com o tempo e o menor índice das réplicas. À esquerda mostra-se os valores finais da energia de cada réplica.	16

Lista de Tabelas

Tabela 2.1 – Exemplo de instância para o MURSER: alguns dos parâmetros das tarefas e máquinas.	7
Tabela 2.2 – Exemplo de instância para o MURSER: tempo de preparo dependentes de sequência. Em azul, os valores usados na solução da Figura 2.1; em vermelho, os valores usados na solução da Figura 2.2.	8
Tabela 3.1 – Comparação entre os principais trabalhos relacionados ao problema estudado.	25
Tabela 4.1 – Planejamento de atividades para Monografia II.	26

Lista de Algoritmos

2.1	Algoritmo de Metropolis (MA)	12
2.2	Revenimento Paralelo (PT)	15

Lista de Abreviaturas e Siglas

AG	Algoritmo genético.
AIS	<i>Artificial immune system.</i>
BD	<i>Benders decomposition.</i>
BRKGA	<i>Biased random-key genetic algorithm.</i>
CEA	<i>Clonal evolution algorithm.</i>
CH	<i>Constructive heuristic.</i>
CP	<i>Constraint programming.</i>
GRASP	<i>Greedy randomized adaptive search.</i>
ICBD	<i>Improved combinatorial Benders decomposition.</i>
IP	<i>Integer programming.</i>
LAHC	<i>Late acceptance hill climbing.</i>
MA	<i>Metropolis algorithm.</i>
MALNS	<i>Modified Adaptive Large Neighbourhood Search.</i>
MARL	<i>Multi-agent reinforcement learning.</i>
MCMC	Markov Chain Monte Carlo.
MHS	<i>Modified harmony search.</i>
MILP	<i>Mixed-integer linear programming.</i>
MURSER	Problema-alvo deste trabalho: <i>makespan on unrelated parallel-machine with release dates, setup times and resource constraint.</i>
NSGA-II	<i>Non-dominated sorting genetic algorithm II.</i>
PT	<i>Parallel tempering — revenimento paralelo.</i>
SA	<i>Simulated annealing.</i>
TEC	<i>Total energy consumption.</i>
TVNS-SA	<i>Two-stage hybrid variable neighborhood search with simulated annealing.</i>

Lista de Símbolos

$\alpha \mid \beta \mid \gamma$	Notação de Graham et al. (1979) — alfa (ambiente de processamento) beta (restrições sobre as tarefas) e gamma (função(ões)-objetivo(s)).
$\mathcal{A}_i$	Conjunto de atribuição na máquina $M_i \in M$.
C_i	Instante de conclusão da máquina $M_i \in M$ no escalonamento.
$C_{\max}$	<i>Makespan</i> , o maior instante de conclusão entre as máquinas. $C_{\max} = \max_{i \in M} C_i$.
f	Função de avaliação.
J	Conjunto de tarefas. $J = \{ J_j \mid 1 \leq j \leq n \}$.
J_j	Tarefa $J_j \in J$.
l_i	Consumo de recurso da máquina $M_i \in M$ por unidade de tempo.
m	Número de máquinas, $m \in \mathbb{N}$.
M	Conjunto de máquinas. $M = \{ M_i \mid 1 \leq i \leq m \}$
M_i	Máquina $M_i \in M$.
n	Número de tarefas, $n \in \mathbb{N}$.
$p_{i,j}$	Tempo de processamento da tarefa $J_j \in J$ na máquina $M_i \in M$.
r_j	Instante em que a tarefa $J_j \in J$ é liberada no ambiente de processamento.
R_m	Ambiente de processamento de m máquinas paralelas não relacionadas.
s	Solução. Aparece também como s' .
$s_{i,j,k}$	Tempo de preparo dependente de sequência da tarefa $J_k \in J$, após a $J_j \in J$, na máquina $M_i \in M$.
σ_i	Sequência de atribuição na máquina $M_i \in M$.
T	Temperatura.
$\overline{U}$	Limite, valor teto do recurso.
U_j	Quantidade de recurso demandada pelo processamento da tarefa $J_j \in J$.

1 Introdução

A manufatura industrial vem passando por uma transição dos tradicionais processos de produção em massa, estáticos e rígidos, para sistemas mais dinâmicos e flexíveis (Alemão; Rocha; Barata, 2021). Além da eficiência operacional desses processos, destaca-se também a capacidade de adaptação das fábricas a diferentes contextos de produção, a fim de atender demandas regulatórias e de mercado. Nesse cenário, insere-se o planejamento da produção, sendo o escalonamento das operações produtivas uma de suas principais vertentes (Serrano-Ruiz; Mula; Poler, 2021). Assim, busca-se coordenar estas operações ao longo do tempo de forma eficiente, de modo a otimizar a utilização dos recursos disponíveis e melhorar o desempenho geral da produção.

Nas indústrias de manufatura, esforços vêm sendo realizados para o uso de recursos de forma eficiente, em um compromisso com a sustentabilidade ecológica (Li et al., 2016). Embora recursos renováveis apresentem menor impacto ambiental, parte substancial das fábricas ainda opera sobre recursos não renováveis, de modo que racionalizá-los possui grande relevância social. Dessa forma, um planejamento produtivo racional é fundamental no gerenciamento do consumo desses recursos ao longo da produção. Na manufatura de semicondutores, por exemplo, esse recurso pode ser representado pela eletricidade, cujo consumo é intenso e deve ser considerado no planejamento das operações da fábrica (Rocholl; Mönch, 2021). Nesse contexto, a utilização de recursos ao longo do processo produtivo passa a ser incorporada como uma restrição no planejamento da produção.

De modo geral, as diversas operações produtivas são denominadas *tarefas* que são processadas por máquinas (Pinedo, 2016). Por exemplo, uma tarefa pode se referir a uma etapa da produção de algum produto, como a impressão do padrão de um circuito integrado no *wafer* na fotolitografia. Por outro lado, uma *máquina* representa um equipamento fabril para o qual uma tarefa pode ser alocada para processamento. No mesmo processo de fotolitografia, uma máquina representa uma impressora de padrão de circuito integrado.

Uma dimensão importante na produção é o custo operacional relacionado ao processamento da tarefa pela máquina, ou seja, o esforço produtivo. O tempo na produção possui papel central neste contexto por representar a ocupação das máquinas, além de refletir este esforço. Assim, uma propriedade que surge do par tarefa-máquina é o *tempo de processamento* — o tempo que a máquina demanda para processar determinada tarefa. Novamente, na fotolitografia, o tempo de processamento varia de acordo com o padrão de impressão específico, diferenciando, assim, as tarefas também.

Cerca de 90% dos problemas de escalonamento consideram que as tarefas podem ter seu processamento iniciado instantaneamente em qualquer máquina disponível (Allahverdi, 2015).

Contudo, uma dimensão extra presente em cenários reais está no fato de que o processamento consecutivo de duas tarefas diferentes em uma mesma máquina pode exigir uma reconfiguração da máquina, o que implica em um *tempo de preparo*. Com efeito, em produções *high-mix*, uma mesma máquina é compartilhada para a produção de diferentes tipos de produtos, e alternar o processamento entre eles custa tempo adicional (Alemão; Rocha; Barata, 2021).

O tempo de preparo pode depender da máquina ou das tarefas envolvidas, denotando o *tempo de preparo dependente de sequência*; mais geralmente, pode depender de ambas. A operação de preparo pode consistir, por exemplo, em limpar e substituir a tinta de uma máquina após o processamento de uma determinada tarefa e antes que outra possa ser processada.

Em cenários reais, as tarefas nem sempre estão disponíveis em qualquer instante de tempo. Desse modo, o planejamento deve considerar que existe um conjunto de tarefas passíveis de serem processadas a cada instante. Isso caracteriza as *datas de disponibilidade* para as tarefas. Em decorrência das diferentes datas de disponibilidade, as máquinas podem ter períodos de ociosidade, resultando em uma menor produtividade. Diante disso, assume-se que as operações de preparação são não antecipatórias, de tal forma que o preparo não pode ser realizada antes de a tarefa estar disponível. Na produção *just-in-time*, por exemplo, com o objetivo de reduzir custos e eliminar gastos desnecessários, a fabricação é feita sob demanda, o que se traduz na liberação das tarefas de forma gradual à medida em que os pedidos de compra são realizados, caracterizando assim naturalmente a presença das datas de disponibilidade.

O *instante de conclusão da tarefa* é definido pelo instante de tempo em que o processamento é de fato finalizado, incluindo, portanto o tempo de processamento da tarefa e o tempo de preparo, caso haja. Já o *instante de conclusão de uma máquina* refere-se ao instante de tempo da conclusão da última tarefa alocada a ela, o que também considera todos os tempos de preparo na máquina.

O ambiente de processamento define a organização das máquinas e sua relação com as tarefas no sistema produtivo. No ambiente de processamento de *máquinas paralelas*, várias máquinas podem estar ativamente processando tarefas em um mesmo dado instante de tempo. No caso mais simples, cada máquina é idêntica às demais, possuindo o mesmo tempo de processamento para cada tarefa. O ambiente de *máquinas paralelas não relacionadas* é mais apropriado para modelar situações gerais, visto que as máquinas podem demandar tempos de processamento diferentes para cada tarefa e também exibir diferentes perfis de consumo de recursos.

Uma das formas de medir a produtividade é analisar o tempo total necessário para concluir todas as tarefas, ou seja, o maior instante de conclusão entre as máquinas do ambiente, o chamado *makespan*. Em um contexto fabril, busca-se minimizar o tempo ocioso das máquinas, já que isto pode ser interpretado como capacidade produtiva não utilizada. Uma maior produtividade advém da utilização mais eficiente das máquinas em paralelo, o que se relaciona diretamente com os tempos de processamento e de preparo. Ambos os aspectos são refletidos diretamente pelo *makespan*.

O conjunto de definições elencado caracteriza um problema combinatório de escalonamento de tarefas. Especificamente, trata-se do problema de minimização do *makespan* em máquinas paralelas não relacionadas, com datas de disponibilidade, tempo de preparo e restrição de recursos (ou, MURSER, de *minimum makespan of unrelated parallel-machines with release dates, setup times and resource constraint*). O MURSER é um problema NP-difícil (Li et al., 2025), uma vez que ele generaliza outros problemas de escalonamento clássicos também NP-difíceis (Lenstra; Rinnooy Kan; Brucker, 1977).

A estratégia utilizada nesta monografia para tratar o MURSER será o método do revenimento paralelo (PT, do inglês *parallel tempering*). O PT é oriundo da simulação de sistemas complexos, porém com aplicações em otimização. Nesta aplicação um parâmetro conjunto de temperaturas age controlando o grau de intensificação ou diversificação das buscas realizadas em paralelo. Uma característica marcante do PT é que as diferentes buscas navegam pelo espaço de temperaturas probabilisticamente, implicando em autocorreção do algoritmo.

A exploração das soluções em paralelo motiva a implementação do PT em computação de alto desempenho. Mesmo sua implementação sequencial já sendo considerada eficiente, o potencial para a computação paralela é alto, proporcionando assim um aumento ainda maior em seu desempenho. Embora reconhecidamente eficaz, o PT não é tão popularmente aplicado na área de Otimização sobretudo por razões históricas (Almeida, 2024). Esta monografia se encaixa nesta lacuna ao aplicar uma implementação paralela do PT a um problema difícil de pesquisa operacional.

1.1 Justificativa

Problemas de escalonamento de tarefas sob o modelo de máquinas paralelas não relacionadas aparecem com frequência em várias vertentes na indústria de manufatura (Đurasević; Jakobović, 2023). Nessas aplicações, restrições no consumo de recursos não renováveis são relevantes, tendo em vista o objetivo de alcançar alta eficiência operacional observando a sustentabilidade da produção (Li et al., 2025). Ademais, considerar os tempos de preparo contribui ainda para soluções mais eficientes no geral ao capturar a estrutura dos problemas de maneira mais realística (Allahverdi; Allahverdi, 2026), o que é mais visível em contextos de produções *high-mix*, em que a variedade de produtos a ser produzida é diversa. Essa eficiência representa uma melhor utilização dos recursos fabris e também se conecta com a sustentabilidade da produção. Por fim, as datas de disponibilidade generalizam a incerteza de quando as tarefas são liberadas no ambiente para o processamento, como no paradigma *just-in-time*.

Uma aplicação particularmente importante do problema abordado ocorre na manufatura de semicondutores devido ao alto grau de automação (Mönch et al., 2011). A crescente demanda atual faz com que os impactos ambientais causados pelo setor tendam a acompanhar seu crescimento. Uma das formas em que a redução das emissões de CO₂ toma na indústria de

semicondutores é na racionalização do consumo de energia elétrica (Ehm et al., 2024).

Apesar de sua aplicabilidade, a complexidade computacional do MURSER o classifica como NP-difícil (Pinedo, 2016; Lenstra; Rinnooy Kan; Brucker, 1977). Em outras palavras, ele pertence a uma classe de problemas computacionais para os quais não se conhece algoritmo resolvidor geral em tempo determinístico polinomial. Na prática, os métodos exatos atualmente conhecidos para o problema de escalonamento tornam-se rapidamente inviáveis à medida que o tamanho da instância aumenta. Tal classificação resulta do fato de que o problema de minimização do *makespan* com a restrição de tempos de preparo é NP-difícil. O ambiente de máquinas paralelas não relacionadas com as restrições abordadas o generaliza; logo, o MURSER também é NP-difícil.

Em decorrência da dificuldade do problema, uma abordagem convencional em escalonamento consiste no emprego de meta-heurísticas (Đurasević; Jakobović, 2023), algoritmos que se baseiam em heurísticas, regras simples, normalmente inspiradas em fenômenos físicos e biológicos, que buscam se aproximar ao máximo da solução ótima. Embora meta-heurísticas sejam viáveis computacionalmente, elas o fazem em detrimento de garantias de otimalidade das soluções.

O potencial de computação paralela do PT o torna particularmente atraente neste cenário, uma vez que uma computação custosa pode ser acelerada de forma natural no método. Com efeito, resultados experimentais mostram que o PT é capaz de reduzir significativamente o tempo de solução de problemas de otimização difíceis (Almeida, 2024). Ademais, como apresentado no mesmo estudo, o método obteve soluções até cerca de 21% melhores que o estado da arte para um problema de escalonamento. Esses resultados evidenciam que o paralelismo no método, além de acelerar a busca, não compromete a qualidade das soluções geradas.

1.2 Objetivos

Dada a motivação, o objetivo desta monografia é aplicar o PT ao MURSER, visando averiguar a qualidade dos resultados obtidos em comparação àqueles observados na literatura. Mais especificamente, objetiva-se:

1. Desenvolver uma revisão da literatura contemplando as características do problema abordado;
2. Apresentar a fundamentação teórica relacionada ao MURSER e ao PT;
3. Implementar um resolvidor para o problema com base no PT;
4. Realizar experimentos e comparar a implementação feita com outros métodos considerando várias instâncias.

Nesta primeira parte da monografia, os objetivos #1 e #2 são abordados. Os objetivos #3 e #4 serão desenvolvidos na segunda parte desta monografia.

1.3 Organização do Trabalho

A estrutura deste trabalho está organizada da seguinte maneira. No Capítulo 2 apresenta-se a fundamentação teórica necessária ao desenvolvimento da monografia, incluindo a descrição do problema de escalonamento considerado, sua notação e os fundamentos do método de revenimento paralelo. No Capítulo 3 revisita a literatura relacionada, com ênfase em problemas de escalonamento em máquinas paralelas não relacionadas com tempos de preparo, datas de disponibilidade e restrições de recursos. O Capítulo 4 apresenta o plano de atividades restantes para a Monografia II. Por fim, o Capítulo 5 reúne as considerações parciais desta primeira etapa do trabalho.

2 Fundamentação Teórica

O presente capítulo começa por descrever o problema e a sua caracterização na teoria de escalonamento em detalhes. Uma visão geral do funcionamento do método de busca PT é então apresentada para o cenário de otimização.

2.1 Descrição do Problema

Considera-se um sistema com n tarefas e m máquinas paralelas. Denota-se por $J = \{J_1, J_2, \dots, J_n\}$ o conjunto de tarefas, e por $M = \{M_1, M_2, \dots, M_m\}$ o conjunto de máquinas. Convencionalmente, o índice i corresponde ao conjunto M , e os índices j e k correspondem ao conjunto J ; para as grandezas temporais, adota-se unidade de tempo $[\delta t]$. Como o objetivo do escalonamento é a alocação temporal das tarefas às máquinas, em cada instante t uma máquina pode processar uma tarefa por uma unidade de tempo. Neste intervalo $[t, t + \delta t[$, a mesma tarefa não pode ser processada por outra máquina, nem mesmo a máquina pode processar outra tarefa.

Para o processamento de uma dada tarefa J_j começar em uma máquina M_i , é necessário que a máquina esteja preparada para processá-la. Assim, o tempo de preparo $s_{i,j}$ diz respeito ao tempo necessário para ajustar a máquina. O tempo de preparo dependente de sequência, ou seja, o tempo para ajustar a máquina M_i para processar a tarefa J_k após a tarefa J_j , é então representado por $s_{i,j,k}$. Nesse caso, $s_{i,0,k}$ corresponde ao tempo para o preparo da primeira tarefa a ser processada pela máquina, em que J_0 é uma tarefa fictícia para esta finalidade.

Tratando-se de um ambiente de máquinas não relacionadas, associado ao par tarefa-máquina há o tempo de processamento $p_{i,j}$. Como o processamento é presumidamente não-preemptivo, uma vez que o processamento de uma tarefa se inicia ele não é interrompido. Denota-se por t_j o instante de início da ocupação da máquina para a tarefa $J_j \in J$, o que inclui sua preparação, e por f_j o seu instante de conclusão. O tempo total em que a tarefa J_k , sequenciada após a tarefa J_j ocupa a máquina M_i é $(f_k - t_k) = (s_{i,j,k} + p_{i,k})$. O instante de tempo em que a tarefa é disponibilizada para o ambiente de produção é representado por r_j . Por se tratar de um contexto não-antecipatório, antes da tarefa estar disponível, nem o processamento e nem a preparação para a tarefa podem ter início (i.e., $t_j \geq r_j$).

Como cada tarefa é atribuída a exatamente uma máquina em um escalonamento, representa-se por $\mathcal{A}_i \subseteq J$ o conjunto de tarefas atribuídas à máquina M_i . Com isso, tem-se que

$$\bigcup_{M_i \in M} \mathcal{A}_i = J,$$

e $\mathcal{A}_{i_1} \cap \mathcal{A}_{i_2} = \emptyset$, com $M_{i_1}, M_{i_2} \in M$, e $i_1 \neq i_2$.

Sendo $|\mathcal{A}_i| = h \in \mathbb{N}$ o número de tarefas atribuídas à determinada máquina M_i , a sequência de atribuição pode ser representada por $\sigma_i = \langle J_{j_1}, J_{j_2}, \dots, J_{j_h} \rangle$, o que corresponde a uma permutação de $\mathcal{A}_i$. A ordem da sequência é tal que, se J_{v_1} precede J_{v_2} na sequência, então $t_{v_1} < t_{v_2}$. As sequências de atribuições são suficientes para especificar uma solução. Assim, se uma tarefa J_k é processada após uma outra J_j na máquina M_i , então $t_k = \max\{r_k, f_j\}$, de modo que o escalonamento pode ser reconstruído a partir delas.

Nesta modelagem, o consumo de recursos é principalmente representado pelo tempo útil de processamento da máquina. Nesta formulação, assume-se que o recurso controlado é consumido apenas durante o processamento das tarefas. Assim, os tempos de preparo afetam o escalonamento por ocuparem a máquina e alterarem os instantes de conclusão, mas não contribuem diretamente para o consumo acumulado do recurso. Diante disso, para uma máquina M_i , assume-se que sua taxa basal de consumo de recurso por unidade de tempo é de l_i , independentemente da tarefa.

Por outro lado, o consumo de recursos associado ao processamento de uma determinada tarefa J_j pode ser representado por U_j . Como somente o tempo de processamento da máquina é relevante, o consumo de recurso pela tarefa é proporcional a este tempo, ou seja, $U_j \propto p_{i,j} \implies U_j = l_i \cdot p_{i,j}$. A restrição de consumo surge então ao impor um determinado valor teto $\bar{U}$, representando um orçamento global do sistema, o qual o consumo total $\mathcal{U} = \sum_{J_j \in J} U_j$ não poderá ultrapassar, i.e., $\mathcal{U} \leq \bar{U}$. Por meio da notação de atribuição $\mathcal{A}_i$, este consumo total $\mathcal{U}$ pode também ser calculado por

$$\mathcal{U} = \sum_{J_j \in J} U_j = \sum_{M_i \in M} l_i \sum_{J_j \in \mathcal{A}_i} p_{i,j}.$$

Para ilustrar uma solução do MURSER, considere a seguinte instância aleatória cujo ambiente possui $m = 2$ e $n = 6$. Os valores $p_{i,j}$, r_j , $s_{i,j,k}$, l_i e $\bar{U}$ são parâmetros da instância. Os tempos de processamento e as datas de disponibilidade são apresentados na Tabela 2.1; em particular, os tempos dependentes de sequência são mostrados na Tabela 2.2. Ademais, $\bar{U} = 32$, e a máquina M_2 será menos eficiente que a M_1 , com $l_1 = 2$, $l_2 = 3$.

Tarefa	$p_{1,j}$	$p_{2,j}$	r_j
J_1	2	2	0
J_2	3	1	0
J_3	1	1	3
J_4	2	2	5
J_5	4	2	6
J_6	1	2	1

Tabela 2.1 – Exemplo de instância para o MURSER: alguns dos parâmetros das tarefas e máquinas.

Tarefas	J_1	J_2	J_3	J_4	J_5	J_6
J_0	2	1	3	5	3	9
J_1	3	4	3	7	3	2
J_2	4	3	1	3	2	2
J_3	4	5	3	2	3	6
J_4	5	3	4	3	6	5
J_5	9	8	8	8	7	5
J_6	4	3	4	2	3	5

(a) Para a máquina M_1 — $s_{1,j,k}$.

Tarefas	J_1	J_2	J_3	J_4	J_5	J_6
J_0	2	1	3	3	3	3
J_1	3	4	3	4	6	3
J_2	9	4	2	4	9	3
J_3	6	9	3	5	1	5
J_4	6	5	3	3	4	8
J_5	5	5	3	4	3	4
J_6	7	5	3	5	2	9

(b) Para a máquina M_2 — $s_{2,j,k}$.

Tabela 2.2 – Exemplo de instância para o MURSER: tempo de preparo dependentes de sequência. Em azul, os valores usados na solução da Figura 2.1; em vermelho, os valores usados na solução da Figura 2.2.

Uma possível solução para o MURSER é ilustrada pela Figura 2.1. Aqui, as sequências de atribuições são $\sigma_1 = \langle J_2, J_3, J_4 \rangle$ e $\sigma_2 = \langle J_1, J_6, J_5 \rangle$. Observe que o primeiro processamento deve ser necessariamente uma das tarefas do conjunto $\{J_1, J_2\}$, visto que elas são as únicas tarefas disponíveis no ambiente no instante $t = 0$. O consumo total de recurso por este escalonamento é de $\mathcal{U} = 2 \times (3 + 1 + 2) + 3 \times (2 + 2 + 2) = 30$.




Figura 2.1 – Gráfico de Gantt para uma solução da instância de exemplo.

Como é possível que existam múltiplos escalonamentos para uma determinada instância, urge assim a necessidade de qualificar as soluções. O instante de conclusão de operação da máquina pode ser visto como sendo $C_i = \max_{J_j \in \mathcal{A}_i} f_j$. Baseado nisto, o *makespan*, definido pela Equação (2.1), corresponde ao maior instante de conclusão entre as máquinas.

$$C_{\max} = \max_{M_i \in M} C_i \quad (2.1)$$

O *makespan* representa o tempo total para o processamento do escalonamento no ambiente. Na solução da Figura 2.1, percebe-se que o tempo total de processamento gasto na máquina M_1 é de $C_1 = 10 [\delta t]$, e de $C_2 = 13 [\delta t]$ em M_2 . Assim sendo, o *makespan* é de $C_{\max} = 13 [\delta t]$. Uma outra solução para essa instância é ilustrada pela Figura 2.2. Nela, as sequências de atribuições são

$\sigma_1 = \langle J_1, J_6, J_4 \rangle$, e $\sigma_2 = \langle J_2, J_3, J_5 \rangle$. O consumo total de recursos é de $\mathcal{U} = 2 \times (2 + 1 + 2) + 3 \times (1 + 1 + 2) = 22$, sendo menor que o da solução anterior. Percebe-se que, embora ambos os escalonamentos sejam válidos para essa instância, o *makespan* $C_{\max} = 11$ $[\delta t]$ desta solução também é menor do que da anterior. Assim, esta é uma melhor solução. E isso apesar de haver um período de ociosidade em M_2 quando $t \in [2, 3[$, o que evidencia o fato de que a ausência de ociosidade não ser critério de otimalidade do escalonamento.




Figura 2.2 – Gráfico de Gantt para uma melhor solução da instância de exemplo.

Pela notação de [Graham et al. \(1979\)](#), $\alpha \mid \beta \mid \gamma$, o MURSER pode ser representado como

$$R_m \mid r_j, s_{i,j,k}, \mathcal{U} \leq \bar{U} \mid C_{\max},$$

em que o primeiro campo, α , corresponde ao ambiente de processamento, e R_m é o ambiente de m máquinas paralelas não relacionadas; o segundo campo, β , corresponde às restrições (e contexto de processamento) sobre as tarefas, sendo r_j a restrição de disponibilidade das tarefas, $s_{i,j,k}$ os tempos de preparo dependentes de sequência, e $\mathcal{U} \leq \bar{U}$ representa a restrição no consumo de recursos. Por fim, o terceiro campo, γ , representa a função de avaliação, neste caso, a minimização do *makespan* — $C_{\max}$.

2.2 Revenimento Paralelo

O revenimento paralelo, também conhecido como *Replica Exchange Monte Carlo* na literatura, é um método amostral estatístico, muito aplicado em simulações físicas ([Earl; Deem, 2005](#)). Este se baseia no algoritmo de Metropolis, que por sua vez se baseia na técnica estatística do *Markov Chain Monte Carlo* (MCMC) empregada para amostrar distribuições de probabilidade complexas. A formulação pode ser adaptada para favorecer a exploração de soluções de menor custo em problemas de otimização combinatória, ainda que não haja garantia de otimalidade. O método é descrito em seguida, logo após a teoria que o fundamenta.

2.2.1 Monte Carlo

Originalmente, o método *Monte Carlo* (Metropolis; Ulam, 1949) foi proposto pelo polonês Stanislaw Ulam para a resolução numérica de equações integro-diferenciais difíceis em problemas físicos. Esses problemas, que surgiam durante o Projeto Manhattan, embora determinísticos, eram tais que suas soluções analíticas eram inviáveis. Destacando o papel central da aleatoriedade, o nome do método foi inspirado no famoso cassino em Mônaco (Summerscales, 2023), se popularizando com o trabalho de Metropolis et al. (1953).

A proposta do Monte Carlo consiste em estimar numericamente valores por meio de amostragem aleatória. Nesse caso, quantidades de interesse, como a esperança de uma função qualquer h , $\mathbb{E}[h(x)]$, ou o resultado de uma integração numérica $I = \int h(x) d\pi$ ¹, podem ser estimadas por meio de estocasticidade, desde que haja convergência do estimador mediante o aumento no número de experimentos amostrais (lei dos grandes números). O avanço dos computadores nesse período possibilitou que simulações numéricas fossem executadas em maior escala, tornando essa abordagem aplicável na prática, e para cenários além daqueles considerados em sua concepção original.

Nos experimentos amostrais do Monte Carlo, pressupõe-se que as amostras são independentes e identicamente distribuídas. Embora a complexidade computacional desses problemas difíceis possa ser reduzida pelos métodos Monte Carlo, à medida que a dimensionalidade dos problemas aumenta, o espaço amostral também se torna muito grande, o que pode deixar o processo amostral do método ainda ineficiente ou mesmo impraticável de ser feito diretamente (Metropolis et al., 1953). Em vista disso, propõe-se empregar as cadeias de Markov (*Markov chains*) no processo de amostragem, como alternativa à abordagem independente, de modo a viabilizar sua aplicação em altas dimensões.

2.2.2 Markov Chain Monte Carlo

As cadeias de Markov são definidas por *estados*, para todo efeito, pontos em um espaço multidimensional, e pela probabilidade condicional de transição entre esses estados, codificada pelo kernel de transição. A cadeia é caracterizada pelos estados na sequência serem determinados, probabilisticamente, exclusivamente a partir do estado anterior. Desse modo, a sequência pode ser interpretada como um encadeamento de variáveis aleatórias evoluindo ao longo do tempo (Robert; Casella, 2004). Nos métodos MCMC, a ideia é construir uma cadeia de Markov cuja *distribuição estacionária* π' , ou seja, a distribuição de probabilidade à qual ela tende a convergir, coincida com a distribuição real de interesse π . Certas propriedades estruturais impostas às cadeias de Markov nesses métodos garantem essa convergência, independentemente da escolha do estado inicial do sistema.

Como, na prática, pode não ser possível avaliar ou amostrar diretamente de π , introduz-se

¹ Em que π é uma distribuição sobre x .

uma distribuição de proposta $q(x_2 | x_1)$, que representa a chance de ir para o estado x_2 a partir do estado x_1 . Nesse contexto, q descreve um mecanismo de amostragem indireta. O algoritmo de [Metropolis et al. \(1953\)](#), ou MA (de *Metropolis algorithm*), consiste em propor iterativamente novos estados na cadeia por meio da distribuição de proposta q e então aceitá-los ou rejeitá-los, como o próximo estado. Este critério de aceitação $\alpha \in [0, 1]$ é usualmente definido como

$$\alpha(x_1, x_2) = \min \left\{ 1, \frac{\pi(x_2)}{\pi(x_1)} \right\},$$

escolhido de forma a satisfazer a propriedade do *equilíbrio detalhado*, e impondo a simetria $q(x_2 | x_1) = q(x_1 | x_2)$ ². Assim, a transição de estado $x_1 \rightarrow x_2$ é aceita com probabilidade $\alpha(x_1, x_2)$, definindo o kernel de transição da cadeia de Markov.

No contexto físico original de mecânica estatística, como estudado por [Metropolis et al. \(1953\)](#), as quantidades de interesse são obtidas a partir da modelagem de um sistema em equilíbrio térmico, que obedecem à distribuição de Boltzmann,

$$\pi(x) \propto e^{-\frac{E(x)}{\kappa_B T}},$$

sendo κ_B a constante de Boltzmann, T a constante *temperatura* e $E(x)$ a *energia* do estado x . Neste caso, a energia é uma grandeza que quantifica o custo associado àquela configuração; a estabilidade da configuração se dá num menor valor de energia. A temperatura representa o grau de dispersão na distribuição de Boltzmann, determinando o quão fortemente a energia influencia a probabilidade dos estados. Segue que essa distribuição também pode ser adotada como distribuição alvo em algoritmos de amostragem no geral, por transformar a energia em uma medida de probabilidade. Dessa forma, pode-se reduzir $\frac{\pi(x_2)}{\pi(x_1)}$ à $e^{-\frac{\Delta E}{T}}$ (em que κ_B é absorvida pela constante T), e então obtém-se a expressão da Equação 2.2, em que $\Delta E = E(x_2) - E(x_1)$ corresponde à variação de energia entre os estados do sistema.

$$\alpha(x_1, x_2) = \min \left\{ 1, e^{-\frac{\Delta E}{T}} \right\}. \quad (2.2)$$

2.2.3 MCMC em Otimização

Os métodos Monte Carlo encontraram sucesso imediato em simulações físico-químicas e pesquisa operacional ([Summerscales, 2023](#)). Particularmente, problemas de otimização quer seriam intratáveis na prática podem ter suas soluções estimadas por meio dessa metodologia, em que o estimador passa a ser o valor mínimo (ou máximo) das amostras obtidas.

Nesse contexto de otimização, os estados x podem ser entendidos como as soluções s para o problema combinatório. Sendo $\mathcal{S}$ o espaço (domínio) das soluções, a energia dos estados é reinterpretada pela função de avaliação $f : \mathcal{S} \rightarrow \mathbb{R}$. Ou seja, um maior valor energético em

² Sem impor essa simetria, [Hastings \(1970\)](#) contribuiu para a formulação do algoritmo expressando o critério de aceitação, mais genericamente, como $\alpha(x_1, x_2) = \min \left\{ 1, \frac{\pi(x_2)q(x_1|x_2)}{\pi(x_1)q(x_2|x_1)} \right\}$.

uma solução corresponde a uma maior valor da função de avaliação. Dessa forma, a busca pelo estado físico de menor energia equivale à busca pelo mínimo da função de avaliação, o que permite interpretar estados estáveis como soluções subótimas ou ótimas da busca, no contexto de minimização. Melhores soluções possuem menores valores da função de avaliação. Neste caso, ΔE é relida como a *degradação da solução*, e pode ser expressa como $\Delta E = f(s') - f(s)$. Quando $\Delta E < 0$, ou seja, há melhoria na solução, o expoente $-\frac{\Delta E}{T} > 0$, o que implica em $e^{-\frac{\Delta E}{T}} > 1 \implies \alpha = 1$, resultando na aceitação da solução proposta. Caso contrário, ou seja, a nova solução for pior do que a atual, sua aceitação dependerá do “quão pior ela é” seguindo a distribuição de Boltzmann.

A constante de temperatura T , definida como um parâmetro, se traduz aqui ao grau de liberdade da busca, coordenando a intensificação e a diversificação do processo. Um maior valor para a temperatura implica em um menor valor do expoente para um mesmo dado valor de ΔE , o que por sua vez implica em uma maior probabilidade de aceitação para a nova solução. Isto é, temperaturas mais altas permitem uma mais alta diversificação, tendendo a aceitar mais soluções propostas. Por sua vez, uma menor temperatura implica em um maior valor do expoente, implicando em uma menor probabilidade de aceitação; a busca passa a alinhar mais com a intensificação, em que apenas maiores valores para $\Delta E > 0$ sejam raramente aceitos, fazendo com que a busca se torne mais localizada.

Ademais, a distribuição de proposta $q(s' | s)$, responsável por gerar uma nova solução candidata, se associa com a relação da vizinhança das soluções. Dada uma solução s , o conjunto de soluções vizinhas $\mathcal{N}(s)$ representa quais soluções são alcançáveis através de pequenas modificações em s . Dessa forma, a distribuição $q(s' | s)$ determina a probabilidade de propor cada elemento dessa vizinhança. Por exemplo, pode-se selecionar uma solução vizinha uniformemente ao acaso, atribuindo a mesma probabilidade a todos os elementos de $\mathcal{N}(s)$. Dessa forma, a dinâmica da cadeia de Markov passa a corresponder a uma caminhada estocástica sobre o espaço de soluções, em que cada transição ocorre entre soluções vizinhas.

Algoritmo 2.1: Algoritmo de Metropolis (MA)

Entrada: Temperatura $T \in \mathbb{R}_*^+$, solução inicial $s^{(0)}$, número de iterações $K \in \mathbb{N}$ — comprimento da cadeia de Markov.

Saída: $s^{(L)}$ — melhor solução encontrada da cadeia.

1 **para** $\ell = 1$ **até** $\ell = K$ **faça**

2 $s' \sim q(s^{(\ell-1)}, \cdot)$

3 $\Delta E \leftarrow f(s') - f(s^{(\ell)})$

4 $z \leftarrow U(0, 1), \alpha \leftarrow \min \left\{ 1, e^{-\frac{\Delta E}{T}} \right\}$

5 $s^{(\ell)} \leftarrow s^{(\ell-1)}$

6 **se** $z < \alpha$ **então**

7 $s^{(\ell)} \leftarrow s'$

8 **retorne** $\arg \min_{s^{(\ell)} \in \mathbf{S}} f(s^{(\ell)})$

O funcionamento do algoritmo Metropolis é descrito no Algoritmo 2.1. A temperatura T é um parâmetro que controlará o grau de intensificação e diversificação da busca; a função de avaliação interpreta a qualidade da solução. A solução inicial $s^{(0)}$ é dada e pode ser arbitrária. O parâmetro K corresponde ao tamanho da cadeia de Markov construída pelo algoritmo. Iterativamente, uma nova solução, a partir da anterior, é proposta (linha 2) por $q(s, \cdot)$, aleatoriamente. A degradação da solução é calculada para essa nova solução na linha 3. Em seguida, na linha 4, realiza-se um experimento aleatório: amostra-se (uniformemente) uma variável aleatória contínua no intervalo $[0, 1]$. Na mesma linha 4, o critério de aceitação α é calculado, com base na distribuição de Boltzmann. A princípio, a ℓ -ésima solução será a mesma da anterior (linha 5), a não ser que a nova seja aceita, que corresponde à z , a variável aleatória, ser menor do que α (linha 6). Caso seja aceita, a ℓ -ésima solução é atualizada para s' , na linha 7. O resultado do algoritmo é a solução da cadeia cuja função de avaliação tenha sido avaliado a mínima entre todas as demais, representado na linha 8.

Do ponto de vista de otimização, o algoritmo de Metropolis comporta-se como uma heurística iterativa estocástica de busca local (Kirkpatrick; Gelatt; Vecchi, 1983). Um problema que pode surgir com o algoritmo de Metropolis é a estagnação em ótimos locais, em que uma barreira energética separa a solução atual de regiões mais promissoras do espaço de busca, dificultando a transição para ótimos melhores globalmente. Na Figura 2.3, o mínimo local em $x = 10$ é separado do global por uma barreira em sua vizinhança. Assim, a busca local pode ficar presa nesse poço em baixas temperaturas, ao passo que, em altas temperaturas, ela consegue escapar da barreira, contudo às custas de também poder abandonar um ótimo global já encontrado.




Figura 2.3 – Ilustração conceitual de um mínimo local separado do mínimo global por uma barreira energética. O eixo das abscissas corresponde ao estado x , ao passo que o eixo das ordenadas corresponde à energia desses estados.

2.2.4 O Revenimento Paralelo

O revenimento paralelo, formalizado por Hukushima e Nemoto (1996), consiste na coordenação de várias *réplicas* do sistema. Cada réplica corresponde a uma cadeia MCMC diferente, simuladas pelo algoritmo de Metropolis independentemente entre si, e a cada uma das ν réplicas do sistema é associada uma determinada temperatura T . Assim, o estado de cada réplica Y_a , em determinado instante, pode ser representada pela sua solução e pela sua temperatura associada — $Y_a = (s_a, T_a)$. No algoritmo, então, cada réplica é processada até atingir um ponto

de “equilíbrio térmico” local da cadeia, isto é, até a estabilização da distribuição estacionária da cadeia de Markov associada àquela temperatura. Em seguida, avalia-se a proposta da troca de réplica entre duas temperaturas em uma *fase de intercâmbio*.

Por simplicidade e por razões de eficiência na taxa de aceitação de réplicas, considera-se somente essa troca entre duas temperaturas adjacentes. Além disso, fixa-se uma orientação para essa troca, representada por $Y_a \xrightarrow{T} Y_{a+1}$, para um índice $1 \leq a < \nu$. Por conveniência, as réplicas são organizadas de forma que a sequência de temperaturas $\langle T_1, T_2, \dots, T_\nu \rangle$ esteja em ordem decrescente.

Mais especificamente, nessa fase de intercâmbio, trabalha-se com o inverso da temperatura $\beta_a = \frac{1}{T_a}$. Uma derivação de Metropolis-Hastings é utilizada para considerar a efetivação das trocas. Para uma troca $Y_a \xrightarrow{T} Y_b$, essa efetivação se baseia na variação do inverso da temperatura (no sentido contrário) $\Delta\beta = \beta_a - \beta_b = \frac{1}{T_a} - \frac{1}{T_b}$ ³ e na degradação da solução entre as réplicas $\Delta E = E(s_b) - E(s_a)$. Assim, o critério de aceitação se baseia na probabilidade segundo a Equação (2.3).

$$\alpha_{\text{troca}} \left(Y_a \xrightarrow{T} Y_b \right) = \min \{ 1, e^{-\Delta\beta \Delta E} \} = \min \{ 1, e^{-(\beta_a - \beta_b)(E(s_b) - E(s_a))} \} \quad (2.3)$$

Essa generalização com respeito ao processo de troca de réplicas no PT é formulada de forma a preservar o equilíbrio detalhado no sistema. Desse modo, a introdução desse mecanismo de intercâmbio não altera a distribuição estacionária que se esperada no conjunto de réplicas, preservando as propriedades assintóticas de convergência do método (Hukushima; Nemoto, 1996).

Por meio desse mecanismo controla-se adicionalmente a intensificação e a diversificação da busca. Com efeito, réplicas associadas a temperaturas elevadas conseguem atravessar barreiras energéticas com maior facilidade, em contraste com o MA, escapando dos mínimos locais, ao passo que réplicas em baixas temperaturas permanecem concentradas em regiões promissoras do espaço de busca.

A seguir o funcionamento do PT é explicado, a partir do Algoritmo 2.2. As temperaturas e soluções iniciais, ou seja, o estado inicial das réplicas $Y_a = (s_a, T_a)$ são parâmetros do algoritmo. O resultado são as soluções de cada réplica depois do processo de amostragem; pode ser também melhor a solução, dentre essas réplicas — linha 9. São executadas Q fases de troca de temperatura pelo algoritmo; a linha 1 corresponde à iteração sobre esse número de rodadas de execução. Em seguida, na linha 2, para toda réplica Y_a , executa-se o MA (Algoritmo 2.1, na linha 3). É válido ressaltar que o parâmetro K para o MA deve ser escolhido de tal forma a solução possa se aproximar suficientemente de seu “equilíbrio térmico”.

As linhas 4-8 correspondem à fase de intercâmbio. Como só trocas entre temperaturas adjacentes são consideradas, só é necessário olhar para a anterior na sequência (de índice $a - 1$);

³ Assim sendo, $\Delta\beta = \Delta T \beta_a \beta_b$ mantém o mesmo sinal de $\Delta T = T_b - T_a$.

a linha 4 exclui o caso inválido para quando $a = 1$. Na linha 5, calcula-se a diferença do inverso da temperatura e a degradação da solução do par. Um experimento aleatório é executado na linha 6, tomando-se um valor uniformemente entre 0 e 1, e o critério de aceitação calculado, com base em $\Delta\beta$ e ΔE (como na Equação 2.3). Caso o experimento suceda, isto é, $z < \alpha$, a troca de temperatura entre as réplicas é concretizada, conforme na linha 8.

Algoritmo 2.2: Revenimento Paralelo (PT)

Entrada: A sequência de temperaturas $\langle T_1, \dots, T_\nu \rangle$, a sequência de soluções iniciais $\langle s_1, \dots, s_\nu \rangle$, tamanho da cadeia de Markov K , quantidade de fases de troca de temperaturas $Q \in \mathbb{N}$.

Saída: Soluções de cada réplica $\langle s'_1, \dots, s'_\nu \rangle$

```

1 para  $t = 1$  até  $t = Q$  faça
2   para  $a = 1$  até  $a = \nu$  faça
3      $s_a \leftarrow \text{MA}(T_a, s_a, K)$ 
4     se  $a > 1$  então
5        $\Delta\beta \leftarrow \left( \frac{1}{T_{a-1}} - \frac{1}{T_a} \right), \Delta E \leftarrow (f(s_a) - f(s_{a-1}))$ 
6        $z \sim U(0, 1), \alpha_{\text{troca}} \leftarrow \min\{1, e^{-\Delta\beta\Delta E}\}$ 
7       se  $z < \alpha_{\text{troca}}$  então
8          $Y_{a-1} \xrightarrow{T} Y_a$ 
9 retorne  $\langle s'_1, \dots, s'_\nu \rangle$ , ou então  $\arg \min_{s_a} f(s_a)$ 

```

A premissa do método é simular as réplicas de forma independente uma das outras, com a única relação entre elas sendo as eventuais trocas de temperaturas. Computacionalmente, este aspecto fomenta o potencial paralelo, em que o algoritmo pode ser dividido explicitamente nas fases de amostragem e intercâmbio, que podem ser verificadas no Algoritmo 2.2, nas linhas 3 e 4-8, respectivamente. Assim, dispõe-se de ν unidades de processamento em paralelo, em que cada uma executa a amostragem corresponde de uma réplica. Posteriormente, elas serão então sincronizadas, e mais uma vez a fase de intercâmbio pode ser executada em paralelo. Mediante uma sincronização final, esse processo se repete Q vezes. Mesmo considerando sua natureza de processamento paralelo do PT, pôde-se ver sucesso mesmo em sua implementação sequencial (Almeida, 2024, Cap. 4.2).

A Figura 2.4 abaixo ilustra o funcionamento do esquema de troca de temperaturas do PT. À medida em que a amostragem se desenvolve no tempo, i.e, a iteração t do algoritmo avança, as réplicas são reassociadas entre as temperaturas. Quanto mais em cima a temperatura está disposta no gráfico, maior seu valor — e menor o valor de β .

① é a única troca que ocorre na iteração $t = 0$, em que $Y_2 \xrightarrow{T} Y_3$. Assim, observa-se que a linha verde (réplica Y_3), antes em T_3 , passa a acompanhar T_2 , e vice-versa para a linha azul (réplica Y_2). Mais tarde, pode-se observar o mesmo padrão de troca com ③ ⑦ ⑨. Acontece

duas trocas $Y_5 \xrightarrow{T} Y_6$, em ② $t = 1$ e ④ $t = 3$. Em seguida, em $t = 4$, ocorre a troca ⑤ em que $Y_4 \xrightarrow{T} Y_5$. Esse mesmo padrão repete em ⑥ ⑧ ⑩. Curiosamente, neste exemplo, as associações de temperaturas e réplicas são as mesmas de quando o algoritmo começou.




Figura 2.4 – Exemplo de funcionamento do intercâmbio de temperaturas no PT. Aqui, $\nu = 6$ e $Q = 12$. As temperaturas estão arranjadas verticalmente. Cada linha colorida representa uma réplica diferente, e temperaturas adjacentes ocasionalmente trocam de réplicas à medida em que se avança na iteração de t , representada na horizontal. As trocas são enumeradas, de 1 a 10, de acordo com o tempo e o menor índice das réplicas. À esquerda mostra-se os valores finais da energia de cada réplica.

Observa-se que não houve trocas com a réplica Y_1 , a linha em vermelho, no exemplo da Figura 2.4. Isso se deve ao valor de $\Delta\beta = \beta_1 - \beta_2$ ser relativamente muito positivo (≈ 70.37); e, sendo $\Delta E = E(Y_2) - E(Y_1) > 0$, o produto se torna relativamente grande, e o valor $e^{-\Delta\beta\Delta E}$ muito pequeno, o que se traduz em uma baixa chance de troca. Quando $t = 11$, por exemplo, $\Delta E \approx 0.029$ e então $\alpha_{\text{troca}} \approx 12.9\%$.

2.2.5 Aplicação

Nesta monografia, o método do PT será aplicado por meio de uma *Application Programming Interface* (API) pública, desenvolvida por Almeida, de Castro Lima e Carvalho (2025), disponibilizada em <<https://github.com/ALBA-CODES/PTAPI>>. Para sua utilização, é necessário definir os adaptadores específicos do problema, isto é, os componentes responsáveis por especializar o algoritmo para o problema de escalonamento abordado neste trabalho.

O primeiro passo consiste em estabelecer a representação computacional do problema para cada uma das partes do algoritmo. Em particular, a *codificação* corresponde ao processo de transformar a representação da instância do problema em uma estrutura de dados adequada, que

será manipulada pelo método durante a execução. A *decodificação*, por sua vez, diz respeito ao processo inverso: transformar a representação de uma solução codificada em uma solução do problema original, respeitando as restrições impostas pela instância.

A *função de avaliação* será responsável por mapear a codificação de uma solução para uma pontuação que represente sua qualidade. A geração das *soluções iniciais* consiste na construção das soluções da população inicial do algoritmo $\langle s_1, \dots, s_\nu \rangle$, que servirão como o ponto de partida para a exploração do espaço de busca. Por fim, a geração da *vizinhança* consiste em produzir novas soluções a partir de uma solução existente, por meio de pequenas modificações em sua representação codificada.

O segundo passo consiste em definir os parâmetros do método, que controlam seu comportamento durante sua execução. São eles:

- ν , o número de réplicas;
- K , o tamanho das cadeias de Markov no MA;
- Q , o número de propostas de troca de réplicas entre temperaturas;
- distribuição das temperaturas iniciais $\langle T_1, \dots, T_\nu \rangle$.

Além disso, com o objetivo de melhorar a eficiência do algoritmo, pode-se propor um esquema de atualização das temperaturas ao longo de sua execução. Para tanto, denota-se por $T_a^{(t)}$ a a -ésima temperatura na iteração t ; as temperaturas são então atualizadas segundo

$$\langle T_1^{(t)}, \dots, T_\nu^{(t)} \rangle \xrightarrow{\text{regra}} \langle T_1^{(t+1)}, \dots, T_\nu^{(t+1)} \rangle,$$

em que a regra considera, por exemplo, o desempenho observado nas tentativas de troca entre as réplicas.

Com esses elementos, encerra-se a fundamentação necessária para a primeira etapa da monografia. O próximo capítulo revisa os trabalhos relacionados ao problema estudado e delimita a contribuição esperada da aplicação do revenimento paralelo.

3 Trabalhos relacionados

Este capítulo revisa trabalhos relacionados ao problema estudado, com ênfase em formulações de escalonamento em máquinas paralelas não relacionadas que incorporam tempos de preparo, datas de disponibilidade e restrições de recursos. A revisão é organizada segundo as principais restrições incorporadas ao problema, de modo a evidenciar quais combinações já foram exploradas na literatura e qual é a posição da presente monografia nesse contexto.

3.1 Critério de seleção dos trabalhos

Esta revisão contempla trabalhos publicados aproximadamente nos últimos dez anos. A seleção da literatura foi orientada pela proximidade dos problemas estudados em relação ao problema abordado, considerando principalmente a presença de duas ou mais das restrições adotadas no ambiente de máquinas paralelas não relacionadas; trabalhos mais distantes foram incluídos apenas quando contribuíam para a modelagem dos recursos ou para os métodos de solução. Esta revisão tem caráter narrativo e orientado por trabalhos de referência, não constituindo uma revisão sistemática exaustiva.

Como apoio à seleção e organização da literatura, utilizam-se revisões abrangentes e estudos de referência com escopos complementares. A revisão de [Allahverdi e Allahverdi \(2026\)](#), que engloba a literatura de 2015 a 2024, é adotada como principal referência para a literatura sobre tempos de preparação em problemas de escalonamento. Para problemas em máquinas paralelas não relacionadas, utiliza-se a revisão de [Durasević e Jakobović \(2023\)](#). Além disso, [Li et al. \(2025\)](#), é tratado como o trabalho mais próximo da formulação estudada nesta monografia, enquanto [Khadivi et al. \(2026\)](#) fornece uma contextualização específica para problemas que combinam tempos de preparo, datas de disponibilidade e restrições de recursos adicionais.

3.2 Tempos de preparo

Os tempos de preparo (no inglês, *setup times*) representam o tempo necessário para preparar os recursos de produção entre tarefas consecutivas. Particularmente, destacam-se os tempos de preparo dependentes da sequência, nos quais a duração da preparação varia conforme a tarefa anteriormente processada, tornando a sequência das tarefas uma decisão central no escalonamento ([Allahverdi; Allahverdi, 2026](#)). Na prática, essa variante da restrição é muito aplicada nesse tipo de problema; no recorte considerado, todos os trabalhos que consideraram tempos de preparo o fizeram considerando a variante dependente de sequência e da máquina.

Entre os trabalhos que consideram tempos de preparo, mas não consideram datas de

disponibilidade, [Bitar et al. \(2016\)](#) estudam uma aplicação em fotolitografia, modelada como um problema de escalonamento em máquinas paralelas não relacionadas com tempos de preparo, recursos auxiliares e restrições de elegibilidade de máquinas. Os autores analisam separadamente dois critérios de otimização: a maximização da produção de *wafers* e a minimização do tempo de fluxo total ponderado. Para resolver o problema, propõem um algoritmo memético.

Por sua vez, [Gomes e Mateus \(2017\)](#) concentram-se no problema $R_m \mid s_{i,j,k} \mid C_{\max}$, representando a vertente de métodos exatos aplicada à variante sem as demais restrições. Esse trabalho evidencia que a presença de tempos de preparo dependentes da sequência, mesmo sem as demais restrições consideradas nesta monografia, já torna a resolução exata suficientemente desafiadora para motivar melhorias específicas nos métodos de solução.

Uma interação particular da restrição é considerada por [Zhang et al. \(2021\)](#), que atribuem os preparos a trabalhadores com diferentes níveis de habilidade de operação de máquinas. Nesse caso, os tempos de preparo dependem da sequência, da máquina e do trabalhador escolhido, possuindo assim quatro dimensões. Sua duração também diminui conforme o trabalhador acumula experiência na máquina, fazendo com que a alocação do recurso humano altere diretamente os tempos das operações de preparo.

Estendendo essa linha de problema para instâncias de maior porte e acrescentando restrições de elegibilidade de máquinas, [Adan \(2022\)](#) propõe um algoritmo genético híbrido para o problema $R_m \mid s_{i,j,k} \mid C_{\max}$, com a adição da restrição de elegibilidade de máquinas. O trabalho destaca que conjuntos maiores de tarefas ampliam as possibilidades de sequenciamento e, conseqüentemente, o potencial de redução dos tempos de preparo, embora também exijam métodos capazes de produzir boas soluções em tempo limitado. Nesse sentido, o método é avaliado em instâncias de até 800 tarefas e 60 máquinas e em uma aplicação real de tecelagem com 2111 tarefas e 133 máquinas.

Os tempos de preparo também podem interagir com restrições de recursos adicionais. [Yepes-Borrero et al. \(2020\)](#), [Zhang et al. \(2021\)](#), [Lopez-Esteve, Perea e Yepes-Borrero \(2023\)](#), [Zampella et al. \(2025\)](#) são exemplos dessa interação e são discutidos na Seção 3.4. Ademais, os trabalhos [Al-harkan e Qamhan \(2019\)](#), [Al-harkan et al. \(2021\)](#), [Athmani et al. \(2022\)](#), [Chang, Chang e Zheng \(2022\)](#), [Yunusoglu e Yildiz \(2022\)](#) consideram também datas de disponibilidade, sendo descritos a seguir.

3.3 Datas de disponibilidade

As datas de disponibilidade (em inglês, *release dates*) representam o instante mais cedo em que uma tarefa pode iniciar seu processamento no sistema, permitindo modelar situações nas quais nem todas as tarefas estão disponíveis no início do horizonte de planejamento ([Pinedo, 2016](#)). Quando essa restrição é combinada com tempos de preparo dependentes da sequência, torna-se necessário determinar se o preparo pode ser realizado antes da liberação da tarefa. Os

preparos são classificados como antecipatórios quando isso é permitido e como não antecipatórios quando também devem aguardar a data de disponibilidade.

[Afzalirad e Rezaeian \(2016\)](#) consideram datas de disponibilidade e tempos de preparo dependentes de sequência juntamente com restrições de elegibilidade, precedência e disponibilidade de recursos renováveis. Tomando essa formulação como antecipatória, [Al-harkan e Qamhan \(2019\)](#) estudam uma variante não antecipatória, mas sem as restrições de elegibilidade de máquinas e precedência, propondo um modelo de programação linear e uma meta-heurística híbrida. Essa variante é posteriormente retomada por [Al-harkan et al. \(2021\)](#), que mantém as restrições de recursos renováveis e propõe um algoritmo de busca harmônica modificada.

Em contraste com essas formulações mais carregadas, [Athmani et al. \(2022\)](#) isolam o problema $R_m \mid r_j, s_{i,j,k} \mid C_{\max}$, considerando preparos não antecipatórios, mas sem as demais restrições operacionais. Além de proporem heurísticas e meta-heurísticas, os autores introduzem um conjunto de 1620 instâncias, estabelecendo uma referência experimental própria para essa combinação de datas de disponibilidade e tempos de preparo. O procedimento empregado para gerar as datas de disponibilidade é posteriormente retomado por [Li et al. \(2025\)](#).

[Yunusoglu e Yildiz \(2022\)](#) retomam essencialmente o conjunto de restrições considerado por [Afzalirad e Rezaeian \(2016\)](#) e propõem uma abordagem exata baseada em programação por restrições. [Chang, Chang e Zheng \(2022\)](#), por sua vez, consideram essencialmente o mesmo conjunto de restrições em uma aplicação industrial biobjetivo, minimizando ambos o $C_{\max}$ e o atraso total $\sum T_j$. Fora da combinação com tempos de preparo, [Caselli et al. \(2024\)](#) também consideram datas de disponibilidade e relações de precedência, propondo um método exato para a variante do problema que minimiza o atraso total ponderado $\sum w_j T_j$.

As datas de disponibilidade também aparecem combinadas a restrições de recursos ou energia em [Li et al. \(2025\)](#), [Perez Bernal, Salido e March Moya \(2025\)](#) e [Khadiji et al. \(2026\)](#), cuja modelagem é discutida em maior detalhe a seguir.

3.4 Restrição de recursos

Em muitas aplicações industriais, a disponibilidade das máquinas não é suficiente para determinar quando uma tarefa pode ser executada. Recursos adicionais, como ferramentas e equipamentos, compartilhados entre as tarefas, podem ser necessários durante o processamento, durante os tempos de preparo ou em ambas as etapas ([Khadiji et al., 2026](#)). Assim, o processamento de uma tarefa só pode se iniciar caso haja disponibilidade da máquina e todos os recursos necessários. Recursos renováveis possuem uma capacidade limitada em cada instante, mas se tornam disponíveis no sistema novamente após sua utilização. Recursos não renováveis, por outro lado, são limitados pelo consumo acumulado durante todo o horizonte de planejamento.

3.4.1 Na etapa de preparo

Yepes-Borrero et al. (2020) introduzem uma variante em que recursos renováveis adicionais são necessários exclusivamente durante os preparos, e não durante o processamento das tarefas. Consequentemente, preparos executados em máquinas diferentes podem competir pelo mesmo recurso, impedindo sua realização simultânea e podendo causar ociosidade nas máquinas. Para minimizar o $C_{\max}$, os autores apresentam uma formulação de programação linear inteira mista e três algoritmos *greedy randomized adaptive search* (GRASP) derivados de heurísticas construtivas distintas, diferenciadas principalmente pela consideração ou não da disponibilidade dos recursos durante a construção inicial das soluções.

Zhang et al. (2021) aprofundam essa representação ao modelar os recursos adicionais como trabalhadores responsáveis pelos preparos, diferenciados por seus níveis de habilidade nas máquinas. A escolha do trabalhador altera a duração do preparo, pois sua eficiência aumenta conforme a experiência acumulada na máquina até atingir um limite de aprendizagem. Para minimizar simultaneamente o $C_{\max}$ e o consumo total de energia (TEC, de *total energy consumption*), os autores propõem um algoritmo evolutivo combinatório que integra as decisões de atribuição das tarefas, sequenciamento e alocação dos trabalhadores.

3.4.2 Na etapa de processamento

Afzalirad e Rezaeian (2016) modelam múltiplos recursos renováveis que são consumidos exclusivamente pelo processamento das tarefas e cuja quantidade demandada depende da tarefa e do tipo de recurso. Os autores propõem duas meta-heurísticas para resolver o problema que se tornam referência na literatura para o problema. Com base nessa mesma representação de recursos, Al-harkan e Qamhan (2019) e Al-harkan et al. (2021) tratam a variante com tempos de preparo não antecipatórios e propõem diferentes abordagens meta-heurísticas para resolver o problema. Neste caso, como o preparo não pode começar antes da data de disponibilidade da tarefa, sua conclusão desloca o início do processamento e, consequentemente, os períodos em que os recursos são demandados.

Yunusoglu e Yildiz (2022) retomam essencialmente o problema de Afzalirad e Rezaeian (2016), substituindo as meta-heurísticas anteriores por uma abordagem exata baseada em programação por restrições. Em uma aplicação industrial multiobjetivo, Chang, Chang e Zheng (2022) também consideram um recurso renovável compartilhado durante o processamento, representado pelos estênceis necessários à montagem das placas de circuito impresso, minimizando o $C_{\max}$ e o atraso total $\sum T_j$ por meio de um algoritmo meta-heurístico.

Em contraste, Bitar et al. (2016), na fotolitografia, representam os recursos como máscaras individuais, das quais existe apenas uma unidade de cada tipo e que permanecem alocadas à máquina durante todo o processamento. Os autores consideram a posição inicial das máscaras e um tempo de transporte quando elas são deslocadas entre máquinas ou para o local de

armazenamento.

Fora da combinação com tempos de preparo, [Caselli et al. \(2024\)](#) representam os recursos renováveis como trabalhadores com capacidades diárias limitadas. Nesse sentido, cada tarefa deve ser atribuída simultaneamente a uma máquina e a um trabalhador compatível, respeitando as horas disponíveis desse trabalhador em cada dia. Essa representação é combinada com datas de disponibilidade, elegibilidade, precedências e relações de contiguidade, sendo o atraso total ponderado $\sum w_j T_j$ minimizado por quatro métodos exatos baseados em programação linear inteira mista, programação por restrições e decomposição combinatória de Benders.

Assim como [Zhang et al. \(2021\)](#), representando os recursos como trabalhadores, [Zampella et al. \(2025\)](#) consideram compatibilidades entre trabalhadores e máquinas, além de uma quantidade de trabalhadores requerida que depende da atribuição entre tarefa e máquina. O critério de otimização é multiobjetivo, envolvendo a minimização de $C_{\max}$, a minimização do consumo total de recursos $\mathcal{U}$, e a maximização do número de tarefas processadas. Para resolver o problema, os autores empregam aprendizado por reforço na atribuição e no sequenciamento das tarefas, considerando simultaneamente o tempo total de execução (preparo e processamento), a utilização dos recursos e o número de tarefas atribuídas.

3.4.3 Em ambas as etapas

[Lopez-Esteve, Perea e Yepes-Borrero \(2023\)](#) estendem o consumo de recursos adicionais renováveis para ambas as etapas, de preparo e processamento. Dessa forma, ambas as operações passam a exigir e a disputar simultaneamente a mesma capacidade. Para minimizar o $C_{\max}$, os autores propõem heurísticas construtivas e algoritmos GRASP, considerando a disponibilidade desses recursos já durante a construção das soluções para a viabilidade.

[Khadiwi et al. \(2026\)](#) investigam também um único tipo de recurso renovável compartilhado em ambas as etapas, acrescentando datas de disponibilidade, prazos de entrega, elegibilidade de máquinas. Além da capacidade do recurso, os autores limitam o número de vezes que ele pode ser transferido entre máquinas em cada período. Dessa forma, o recurso não pode ser deslocado livremente entre as máquinas, mesmo quando sua capacidade total seria suficiente para executar as operações. Os autores propõem um modelo de programação linear inteira mista e um algoritmo genético de chaves aleatórias viciadas para resolver o problema (BRKGA, de *biased random-key genetic algorithm*).

3.4.4 Recurso não renovável

Em contraste com as variantes renováveis anteriores, [Li et al. \(2025\)](#) consideram um único recurso não renovável limitado pelo seu consumo total ao longo do escalonamento. Ademais, consideram também as restrições de datas de disponibilidade e tempos de preparo não antecipatórios. O consumo de cada tarefa depende da máquina escolhida e de seu tempo de

processamento, enquanto os tempos de preparo não consomem esse recurso. Dessa forma, a atribuição das tarefas influencia simultaneamente o $C_{\max}$ e o orçamento global disponível. Para essa variante, os autores apresentam uma formulação de programação linear inteira mista e um algoritmo de busca adaptativa em grande vizinhança modificada.

Em conjunto, os trabalhos revisados distinguem-se pela natureza do recurso e pela etapa em que sua disponibilidade é exigida, o que modifica as condições de viabilidade e a interação entre as decisões de atribuição e sequenciamento. Por outro lado, variantes que consideram o consumo de recursos apenas como critério de otimização, sem restringir a viabilidade das soluções, como faz [Perez Bernal, Salido e March Moya \(2025\)](#), por exemplo, não foram incluídas nesta classificação. A seguir, a Seção 3.5 sintetiza essas diferenças e posiciona a formulação adotada nesta monografia em relação às variantes mais próximas.

3.5 Síntese da literatura e posicionamento da monografia

A partir desta revisão, observa-se que os tempos de preparo e as datas de disponibilidade aparecem em grande parte dos trabalhos analisados, enquanto a restrição de recursos adicionais aparece de alguma forma em boa parte do recorte considerado. Quando presente, essa restrição concentra diferenças importantes entre as formulações, sendo majoritariamente modelada por meio de recursos renováveis. No recorte analisado, identificou-se apenas o trabalho de [Li et al. \(2025\)](#) incorporando uma restrição global de recurso não renovável ao ambiente de máquinas paralelas não relacionadas com datas de disponibilidade e tempos de preparo dependentes da sequência. Dependendo da aplicação, esses recursos podem ser requeridos durante o processamento das tarefas, durante as operações de preparo ou em ambas as etapas. Também podem representar trabalhadores com diferentes habilidades ou apresentar limitações de movimentação entre máquinas, como discutido por [Khadivi et al. \(2026\)](#).

Devido à natureza NP-difícil dos problemas abordados, observa-se uma divisão entre os métodos de solução empregados. Modelos exatos são utilizados principalmente em instâncias de menor porte e como referência para a avaliação de outros métodos. Para instâncias maiores, predominam heurísticas e meta-heurísticas, que buscam produzir soluções de qualidade em tempo computacional viável. Essa divisão aparece tanto nas variantes com recursos renováveis quanto naquelas que incorporam outras restrições operacionais, como elegibilidade de máquinas, precedência e datas de disponibilidade.

Entre os trabalhos revisados, [Li et al. \(2025\)](#) apresentam a formulação mais próxima da considerada nesta monografia, tratando o problema de minimização do *makespan* em máquinas paralelas não relacionadas com datas de disponibilidade, tempos de preparo dependentes da sequência e restrição global de recurso não renovável. Em particular, os autores consideram um recurso adicional cujo consumo acumulado ao longo do horizonte de planejamento não pode

exceder um orçamento global. Essa formulação difere da maioria dos trabalhos analisados, nos quais os recursos são renováveis e restringem a capacidade disponível em cada instante de tempo.

Mais especificamente, para resolver o problema, os autores propõem um modelo de programação inteira para instâncias de pequeno porte e uma meta-heurística denominada *Modified Adaptive Large Neighbourhood Search* (MALNS) para instâncias maiores. O algoritmo adapta a estrutura do ALNS ao tratamento da restrição global de recursos por meio de mecanismos específicos de reparo de soluções inviáveis e de busca local. Nos experimentos, realizados sobre um conjunto de 1440 instâncias sintéticas, o MALNS é comparado ao modelo exato e a três meta-heurísticas adaptadas da literatura aplicadas a problemas relacionados, a saber, o GRASP, o BRKGA e o algoritmo genético (AG), apresentando os melhores resultados em comparação aos métodos avaliados para as instâncias de grande porte.

A Tabela 3.1 apresenta as principais características dos trabalhos discutidos neste capítulo e posiciona o problema desta monografia em relação às variantes encontradas na literatura.

Tabela 3.1 – Comparação entre os principais trabalhos relacionados ao problema estudado.

Referência	r_j	$s_{i,j,k}$	Tipo de recurso e etapa (S/P)	Função(ões)-objetivo	Método(s)
Afzalirad e Rezaeian (2016)	✓	✓	Renovável / P	$C_{\max}$	IP, AG, AIS
Bitar et al. (2016)		✓	Renovável / P	$\sum w_j f_j, \sum c_j \theta_j$	Algoritmo memético
Gomes e Mateus (2017)		✓	—	$C_{\max}$	ICBD
Al-harkan e Qamhan (2019)	✓	✓	Renovável / P	$C_{\max}$	MILP, TVNS-SA
Yepes-Borrero et al. (2020)		✓	Renovável / S	$C_{\max}$	MILP, GRASP
Zhang et al. (2021)		✓	Renovável / S	$C_{\max}, \text{TEC}$	CEA
Al-harkan et al. (2021)	✓	✓	Renovável / P	$C_{\max}$	MHS
Adan (2022)		✓	—	$C_{\max}$	AG híbrido
Athmani et al. (2022)	✓	✓	—	$C_{\max}$	LAHC, SA
Chang, Chang e Zheng (2022)	✓	✓	Renovável / P	$C_{\max}, \sum T_j$	MILP, NSGA-II
Yunusoglu e Yildiz (2022)	✓	✓	Renovável / P	$C_{\max}$	CP
Lopez-Esteve, Perea e Yepes-Borrero (2023)		✓	Renovável / P&S	$C_{\max}$	CH, GRASP
Caselli et al. (2024)	✓		Renovável / P	$\sum w_j T_j$	MILP, CP, BD
Li et al. (2025)	✓	✓	Não renovável / P	$C_{\max}$	MILP, MALNS
Zampella et al. (2025)		✓	Renovável / P	$C_{\max}, \mathcal{U}, \text{nº de tarefas processadas}$	MARL
Khadivi et al. (2026)	✓	✓	Renovável / P&S	$C_{\max}$	MILP, BRKGA
Esta monografia	✓	✓	Não renovável / P	$C_{\max}$	PT

S: etapa de preparo (*setup*); P: etapa de processamento. As siglas dos métodos ainda não mencionadas são: AIS: Artificial immune system; BD: Benders decomposition; CEA: Clonal evolution algorithm; CP: Constraint programming; ICBD: Improved combinatorial Benders decomposition; IP: Integer programming; LAHC: Late acceptance hill climbing; MARL: Multi-agent reinforcement learning; MILP: Mixed integer linear programming; MHS: Modified harmony search; NSGA-II: Non-dominated sorting genetic algorithm II; SA: Simulated annealing; TVNS-SA: Two-stage hybrid variable neighborhood search with simulated annealing.

Por fim, a revisão realizada evidencia que o problema abordado nesta monografia combina restrições frequentemente estudadas de forma isolada, mas ainda pouco exploradas em conjunto no ambiente de máquinas paralelas não relacionadas. Em particular, a combinação de tempos de preparo dependentes da sequência, datas de disponibilidade e restrição global de consumo de um recurso não renovável permanece limitada na literatura. Pela proximidade entre as formulações, [Li et al. \(2025\)](#) constitui a principal referência para a comparação dos resultados futuros desta monografia. Nesse panorama, este trabalho propõe investigar o revenimento paralelo como alternativa ao MALNS empregado por [Li et al. \(2025\)](#), avaliando sua competitividade na obtenção de soluções de boa qualidade para o problema estudado.

4 Plano de Atividades Restantes

O desenvolvimento deste trabalho terá continuidade na segunda etapa da monografia. Para esse fim, o plano das atividades restantes previstas para sua execução é apresentado na Tabela 4.1.

Atividades	Mês 1	Mês 2	Mês 3	Mês 4
Adaptação da API do PT para o MURSER	•	•		
Conjunto de instâncias		•		
Testes para calibração de parâmetros		•	•	
Realização dos experimentos computacionais		•	•	
Descrição e análise dos experimentos			•	
Conclusão da Monografia				•

Tabela 4.1 – Planejamento de atividades para Monografia II.

Na segunda etapa da monografia, o foco será a implementação e avaliação experimental do método. Inicialmente, a API do revenimento paralelo será adaptada ao problema estudado por meio da definição da representação das soluções, do procedimento de decodificação, da função de avaliação e das estruturas de vizinhança. Em seguida, serão selecionadas as instâncias de teste e realizada a calibração dos principais parâmetros do algoritmo. Por fim, os experimentos computacionais serão executados e analisados em comparação com os resultados disponíveis na literatura.

5 Conclusão

Nesta primeira etapa da monografia, foi apresentada a fundamentação necessária para o estudo do problema de minimização do makespan em máquinas paralelas não relacionadas com tempos de preparo dependentes da máquina e da sequência, datas de disponibilidade e restrição global no consumo de recursos. O problema foi formalizado, suas principais características foram discutidas e sua relevância foi contextualizada em aplicações de manufatura.

Também foram apresentados os fundamentos do revenimento paralelo, incluindo sua relação com métodos de Monte Carlo, cadeias de Markov, algoritmo de Metropolis e mecanismos de troca entre réplicas em diferentes temperaturas. A revisão bibliográfica permitiu identificar os trabalhos mais próximos do problema considerado e posicionar [Li et al. \(2025\)](#) como principal referência para comparação futura.

Na Monografia II, serão desenvolvidas a adaptação da API de revenimento paralelo ao problema estudado, a definição dos componentes específicos do método, a calibração de parâmetros e a execução dos experimentos computacionais. Os resultados obtidos serão comparados com os principais valores reportados na literatura, de modo a avaliar a competitividade da abordagem proposta.

Referências

ADAN, J. A hybrid genetic algorithm for parallel machine scheduling with setup times. *Journal of Intelligent Manufacturing*, v. 33, n. 7, p. 2059–2073, 2022. ISSN 1572-8145. Disponível em: <https://doi.org/10.1007/s10845-022-01959-4>.

AFZALIRAD, M.; REZAEIAN, J. Resource-constrained unrelated parallel machine scheduling problem with sequence dependent setup times, precedence constraints and machine eligibility restrictions. *Computers & Industrial Engineering*, v. 98, p. 40–52, 2016. ISSN 0360-8352. Disponível em: <https://doi.org/10.1016/j.cie.2016.05.020>.

AL-HARKAN, I. M.; QAMHAN, A. A. Optimize unrelated parallel machines scheduling problems with multiple limited additional resources, sequence-dependent setup times and release date constraints. *IEEE Access*, v. 7, p. 171533–171547, 2019. Disponível em: <https://doi.org/10.1109/ACCESS.2019.2955975>.

AL-HARKAN, I. M.; QAMHAN, A. A.; BADWELAN, A.; ALSAMHAN, A.; HIDRI, L. Modified harmony search algorithm for resource-constrained parallel machine scheduling problem with release dates and sequence-dependent setup times. *Processes*, v. 9, n. 4, 2021. ISSN 2227-9717. Disponível em: <https://www.mdpi.com/2227-9717/9/4/654>.

ALEMÃO, D.; ROCHA, A. D.; BARATA, J. Smart manufacturing scheduling approaches—systematic review and future directions. *Applied Sciences*, v. 11, n. 5, p. 4074–4098, 2021. ISSN 2076-3417. Disponível em: <https://www.mdpi.com/2076-3417/11/5/2186>.

ALLAHVERDI, A. The third comprehensive survey on scheduling problems with setup times/costs. *European Journal of Operational Research*, v. 246, n. 2, p. 345–378, 2015. ISSN 0377-2217. Disponível em: <https://www.sciencedirect.com/science/article/pii/S0377221715002763>.

ALLAHVERDI, A.; ALLAHVERDI, M. The fourth comprehensive review of scheduling problems with setup times. *European Journal of Operational Research*, 2026. ISSN 0377-2217. Disponível em: <https://www.sciencedirect.com/science/article/pii/S0377221726003140>.

ALMEIDA, A. L. B. *Revisitando o Revenimento Paralelo: Computação de Alto Desempenho e Aplicação em Pesquisa Operacional*. Tese (Tese de doutorado) — Universidade Federal de Ouro Preto, Ouro Preto, Agosto 2024.

ALMEIDA, A. L. B.; de Castro Lima, J.; CARVALHO, M. A. M. Revisiting the parallel tempering algorithm: High-performance computing and applications in operations research. *Computers & Operations Research*, v. 178, p. 107000, 2025. ISSN 0305-0548. Disponível em: <https://www.sciencedirect.com/science/article/pii/S0305054825000280>.

ATHMANI, M. E.; ARBAOUI, T.; MIMENE, Y.; YALAOUI, F. Efficient heuristics and metaheuristics for the unrelated parallel machine scheduling problem with release dates and setup times. In: *Proceedings of the Genetic and Evolutionary Computation Conference*. New York, NY, USA: Association for Computing Machinery, 2022. (GECCO '22), p. 177–185. ISBN 9781450392372. Disponível em: <https://doi.org/10.1145/3512290.3528857>.

BITAR, A.; DAUZÈRE-PÉRÈS, S.; YUGMA, C.; ROUSSEL, R. A memetic algorithm to solve an unrelated parallel machine scheduling problem with auxiliary resources in semiconductor manufacturing. *Journal of Scheduling*, v. 19, n. 4, p. 367–376, 2016. Disponível em: <https://doi.org/10.1007/s10951-014-0397-6>.

CASELLI, G.; DELORME, M.; IORI, M.; MAGNI, C. A. Exact algorithms for a parallel machine scheduling problem with workforce and contiguity constraints. *Computers & Operations Research*, v. 163, p. 106484, 2024. ISSN 0305-0548. Disponível em: <https://www.sciencedirect.com/science/article/pii/S0305054823003489>.

CHANG, Y.-C.; CHANG, K.-H.; ZHENG, C.-P. Application of a non-dominated sorting genetic algorithm to solve a bi-objective scheduling problem regarding printed circuit boards. *Mathematics*, v. 10, n. 13, 2022. ISSN 2227-7390. Disponível em: <https://www.mdpi.com/2227-7390/10/13/2305>.

EARL, D. J.; DEEM, M. W. Parallel tempering: Theory, applications, and new perspectives. *Physical Chemistry Chemical Physics*, Royal Society of Chemistry (RSC), v. 7, n. 23, p. 3910–3916, 2005. ISSN 1463-9084. Disponível em: <http://dx.doi.org/10.1039/B509983H>.

EHM, H.; ISMAIL, A.; NAYAK, R.; SERR, S.; SCHEUERMANN, T. Simulation for an energy-efficient semiconductor manufacturing network. In: *Proceedings of the Winter Simulation Conference (WSC)*. [s.n.], 2024. Disponível em: <https://doi.org/10.1109/WSC63780.2024.10838903>.

GOMES, F. R. A.; MATEUS, G. R. Improved combinatorial benders decomposition for a scheduling problem with unrelated parallel machines. *Journal of Applied Mathematics*, v. 2017, n. 1, p. 9452762, 2017. Disponível em: <https://onlinelibrary.wiley.com/doi/abs/10.1155/2017/9452762>.

GRAHAM, R.; LAWLER, E.; LENSTRA, J.; KAN, A. Optimization and approximation in deterministic sequencing and scheduling: a survey. In: HAMMER, P.; JOHNSON, E.; KORTE, B. (Ed.). *Discrete Optimization II*. Elsevier, 1979, (Annals of Discrete Mathematics, v. 5). p. 287–326. Disponível em: <https://www.sciencedirect.com/science/article/pii/S016750600870356X>.

HASTINGS, W. K. Monte carlo sampling methods using markov chains and their applications. *Biometrika*, v. 57, n. 1, p. 97–109, 04 1970. ISSN 0006-3444. Disponível em: <https://doi.org/10.1093/biomet/57.1.97>.

HUKUSHIMA, K.; NEMOTO, K. Exchange monte carlo method and application to spin glass simulations. *Journal of the Physical Society of Japan*, v. 65, n. 6, p. 1604–1608, 1996. Disponível em: <https://doi.org/10.1143/JPSJ.65.1604>.

KHADIVI, M.; TIERNEY, K.; ABBASI, M.; CHARTER, T.; NAJJARAN, H. Resource-constrained parallel machine scheduling with setups, job release/due time, and resource transition limit. *European Journal of Operational Research*, 2026. ISSN 0377-2217. Disponível em: <https://www.sciencedirect.com/science/article/pii/S0377221726004704>.

KIRKPATRICK, S.; GELATT, C.; VECCHI, M. Optimization by simulated annealing. *Science (New York, N.Y.)*, v. 220, p. 671–80, 06 1983. Disponível em: <https://doi.org/10.1126/science.220.4598.671>.

- LENSTRA, J.; Rinnooy Kan, A.; BRUCKER, P. Complexity of machine scheduling problems. In: HAMMER, P.; JOHNSON, E.; KORTE, B.; NEMHAUSER, G. (Ed.). *Studies in Integer Programming*. Elsevier, 1977, (Annals of Discrete Mathematics, v. 1). p. 343–362. Disponível em: <https://www.sciencedirect.com/science/article/pii/S016750600870743X>.
- LI, K.; WANG, Z.; XIE, F.; CHEN, J.; XU, L. Resource-constrained scheduling of unrelated parallel machines with release times and setup times. *Engineering Optimization*, Taylor & Francis, sep 2025. Disponível em: <https://www.tandfonline.com/doi/full/10.1080/0305215X.2025.2547946>.
- LI, K.; ZHANG, X.; LEUNG, J. Y.-T.; YANG, S.-L. Parallel machine scheduling problems in green manufacturing industry. *Journal of Manufacturing Systems*, v. 38, p. 98–106, 2016. ISSN 0278-6125. Disponível em: <https://www.sciencedirect.com/science/article/pii/S0278612515001296>.
- LOPEZ-ESTEVE, A.; PEREA, F.; YEPES-BORRERO, J. C. Grasp algorithms for the unrelated parallel machines scheduling problem with additional resources during processing and setups. *International Journal of Production Research*, Taylor & Francis, v. 61, n. 17, p. 6013–6029, 2023. Disponível em: <https://doi.org/10.1080/00207543.2022.2121869>.
- METROPOLIS, N.; ROSENBLUTH, A. W.; ROSENBLUTH, M. N.; TELLER, A. H.; TELLER, E. Equation of state calculations by fast computing machines. *The Journal of Chemical Physics*, v. 21, n. 6, p. 1087–1092, 06 1953. ISSN 0021-9606. Disponível em: <https://doi.org/10.1063/1.1699114>.
- METROPOLIS, N.; ULAM, S. The monte carlo method. *Journal of the American Statistical Association*, Taylor & Francis, v. 44, n. 247, p. 335–341, 1949. PMID: 18139350. Disponível em: <https://www.tandfonline.com/doi/abs/10.1080/01621459.1949.10483310>.
- MÖNCH, L.; FOWLER, J. W.; DAUZÈRE-PÉRÈS, S.; MASON, S. J.; ROSE, O. A survey of problems, solution techniques, and future challenges in scheduling semiconductor manufacturing operations. *Journal of Scheduling*, v. 14, n. 6, p. 583–599, 2011. Disponível em: <https://doi.org/10.1007/s10951-010-0222-9>.
- Perez Bernal, C.; SALIDO, M. A.; March Moya, C. Optimizing energy efficiency in unrelated parallel machine scheduling problem through reinforcement learning. *Information Sciences*, v. 693, p. 121674, 2025. ISSN 0020-0255. Disponível em: <https://www.sciencedirect.com/science/article/pii/S0020025524015883>.
- PINEDO, M. L. *Scheduling: Theory, Algorithms, and Systems*. 5. ed. Springer, 2016. Disponível em: <https://doi.org/10.1007/978-3-319-26580-3>.
- ROBERT, C. P.; CASELLA, G. *Monte Carlo Statistical Methods*. 2. ed. Springer NY, 2004. ISBN 978-1-4757-4145-2. Disponível em: <https://doi.org/10.1007/978-1-4757-4145-2>.
- ROCHOLL, J.; MÖNCH, L. Simulation-based performance assessment of sustainable manufacturing decisions. In: *2021 Winter Simulation Conference (WSC)*. [s.n.], 2021. p. 1–12. Disponível em: <https://doi.org/10.1109/WSC52266.2021.9715518>.
- SERRANO-RUIZ, J. C.; MULA, J.; POLER, R. Smart manufacturing scheduling: A literature review. *Journal of Manufacturing Systems*, v. 61, p. 265–287, 2021. ISSN 0278-6125. Disponível em: <https://www.sciencedirect.com/science/article/pii/S0278612521001977>.

SUMMERSCALES, O. Hitting the jackpot: The birth of the monte carlo method. *Actinide Research Quarterly*, Los Alamos National Laboratory, nov. 2023. Disponível em: <<https://www.lanl.gov/media/publications/actinide-research-quarterly/1123-hitting-the-jackpot-the-birth-of-the-monte-carlo-method>>.

YEPES-BORRERO, J. C.; VILLA, F.; PEREA, F.; CABALLERO-VILLALOBOS, J. P. Grasp algorithm for the unrelated parallel machine scheduling problem with setup times and additional resources. *Expert Systems with Applications*, v. 141, p. 112959, 2020. ISSN 0957-4174. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0957417419306773>>.

YUNUSOGLU, P.; YILDIZ, S. T. Constraint programming approach for multi-resource-constrained unrelated parallel machine scheduling problem with sequence-dependent setup times. *International Journal of Production Research*, Taylor & Francis, v. 60, n. 7, p. 2212–2229, 2022. Disponível em: <<https://doi.org/10.1080/00207543.2021.1885068>>.

ZAMPELLA, M.; OTAMENDI, U.; BELAUNZARAN, X.; ARTETXE, A.; OLAIZOLA, I. G.; SIERRA, B.; LONGO, G. Exploring multi-agent reinforcement learning for unrelated parallel machine scheduling. *The Journal of Supercomputing*, v. 81, n. 4, p. 521, 2025. ISSN 1573-0484. Disponível em: <<https://doi.org/10.1007/s11227-025-07030-2>>.

ZHANG, L.; DENG, Q.; LIN, R.; GONG, G.; HAN, W. A combinatorial evolutionary algorithm for unrelated parallel machine scheduling problem with sequence and machine-dependent setup times, limited worker resources and learning effect. *Expert Systems with Applications*, v. 175, p. 114843, 2021. ISSN 0957-4174. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0957417421002840>>.

DURASEVIĆ, M.; JAKOBOVIĆ, D. Heuristic and metaheuristic methods for the parallel unrelated machines scheduling problem: a survey. *Artificial Intelligence Review*, v. 56, n. 4, p. 3181–3289, 2023. Disponível em: <<https://doi.org/10.1007/s10462-022-10247-9>>.